

Racismo algoritmo

A reportagem foca na trajetória de Nina da Hora, cientista da computação brasileira que investiga como algoritmos de IA reproduzem os preconceitos presentes na sociedade, destacando que a neutralidade da máquina é um mito, já que a tecnologia é construída por pessoas com seus próprios vieses. Como ponto positivo, a obra humaniza a pauta em questão e facilita o entendimento de como o racismo afeta o cotidiano, embora apresente como ponto negativo o fato de que, por se tratar de uma breve entrevista, os dados não são profundamente técnicos, priorizando um contexto mais emocional e biográfico em detrimento da densidade acadêmica.

A contribuição de Nina da Hora é fundamental porque ela retira o debate sobre IA do campo puramente abstrato ou estrangeiro e o traz para a realidade social brasileira. Minha percepção sobre esta obra é que ela cumpre um papel ético : denunciar que a tecnologia não é "perfeita" , mas sim um produto de escolhas humanas. Além disso, a obra provoca uma reflexão necessária sobre a soberania tecnológica. A fonte evidencia que, sem o olhar crítico de pessoas que sofrem o racismo na pele, a tecnologia continuará sendo uma ferramenta de exclusão disfarçada de inovação.

3 types of bias in AI

O vídeo produzido pelo Google aborda de forma didática como o preconceito humano é transferido para as máquinas através do aprendizado de máquina (machine learning). O foco central do vídeo é demonstrar o erro presente na ideia de que, por serem baseados em dados, os computadores são naturalmente neutros. A obra categoriza o viés em três tipos principais, sendo eles, o Viés de Interação, Viés Latente e o Viés de Seleção. É um ponto positivo ver uma gigante da tecnologia "admitir" a imperfeição em um tipo de aplicação presente em seu ecossistema, porém, ao mesmo tempo, por ser um vídeo curto e institucional, ele não se aprofunda nas consequências/danos sociais de tal fato.

Esse tipo de vídeo é muito importante para o esclarecimento de como os processos por trás dos avanços tecnológicos funcionam, a desmistificação da ideia sobre a neutralidade computacional perante ao fato óbvio da existência do preconceito na sociedade, principalmente quando vinda de uma gigante tecnológica, ajuda na transparência com os usuários de tais tecnologias e com a sociedade como um todo, contribuindo assim para um maior "senso" social global.

The Butterfly Effect in AI Systems

O artigo de Emilio Ferrara utiliza o conceito "Efeito Borboleta" para analisar a falta de equidade e os vieses em sistemas de Inteligência Artificial. O autor argumenta que a IA é um sistema complexo e não linear, onde pequenas alterações iniciais podem desencadear resultados finais desproporcionalmente injustos. O texto explora como esses pequenos desvios se amplificam através de "ciclos de retroalimentação" (feedback loops), onde um sistema enviesado gera novos dados também enviesados, perpetuando a discriminação contra grupos marginalizados em áreas como saúde, contratação e reconhecimento facial. Esse artigo, além de diagnosticar o problema, ele também propõe estratégias empíricas para medir e combater esse efeito, porém a linguagem acadêmica densa e o uso de conceitos da física e matemática podem tornar a leitura exaustiva ou inacessível para o público leigo.

Para mim, esse artigo, por se tratar de algo mais denso e aprofundado acaba a ter um público alvo mais específico e diferente dos demais, trazendo complexidade ao tema, e uma maior atenção proveniente de especialistas da área, que se aprofundam em questões mais teóricas, como as retratadas no artigo. Esse tipo de atenção é necessário para uma maior influência do tema e realização de sua proposta de intervenção.

Algorithmic Bias in AI: What It Is and How to Fix It

Este vídeo da IBM Technology explora as causas técnicas e as estratégias de mitigação do viés algorítmico. A obra define que o viés não é necessariamente causado pelo algoritmo em si, mas por

como os dados são coletados e codificados. O conteúdo detalha quatro causas principais, Dados de Treinamento Ruins: Dados não representativos ou classificados incorretamente. Design Algorítmico: Erros de programação ou pesos subjetivos atribuídos por desenvolvedores (consciente ou inconscientemente). Dados de Proxy: O uso de variáveis "substitutas" que mascaram preconceitos (como usar o CEP como indicador de classe social ou raça). Viés de Avaliação: Como humanos interpretam e aplicam os resultados da máquina de forma tendenciosa. Um ponto positivo é que, diferente de outras fontes que apenas diagnosticam o problema, esta oferece um roteiro de "como consertar", mencionando auditorias algorítmicas e avaliações de impacto, porém a abordagem é focada em "governança" e "ajustes de sistema", o que pode passar a impressão de que o racismo é apenas um problema técnico de eficiência que pode ser resolvido com as ferramentas certas da própria indústria.

Minha análise crítica sobre a obra é que ela oferece uma ponte necessária entre o problema social e a solução técnica, mas o faz sob uma ótica estritamente corporativa que corre o risco de reduzir o racismo a somente um "erro de processamento". O ponto mais alto da obra é a explicação sobre os dados de Proxy (como o uso de CEPs para mascarar exclusão racial), pois revela como a discriminação pode ser matematicamente sofisticada e "invisível" em sistemas aparentemente neutros. Em última análise, a obra é excelente para entender as engrenagens técnicas do viés, mas deve ser consumida com a consciência de que a ética na IA não é apenas uma questão de "limpar dados", mas de mudar radicalmente quem detém o poder de decisão e a diversidade por trás do código.

Visão Computacional e Racismo Algorítmico

O artigo científico de Tarcízio Silva investiga como as tecnologias de visão computacional (reconhecimento facial e classificação de imagens) reproduzem o racismo através da "branquitude" e da "opacidade". O autor utiliza a Teoria Racial Crítica para mapear casos públicos onde pessoas negras foram invisibilizadas por sensores (que não reconheciam seus tons de pele) ou hiper-vigiadas por sistemas de segurança. O texto argumenta que os bancos de dados usados para treinar essas IAs não são apenas falhos, mas refletem uma estrutura de poder onde o rosto branco é estabelecido como o padrão universal ("humano"), enquanto o rosto negro é tratado como um desvio ou uma ameaça.

Diferente das fontes puramente técnicas, esta obra conecta a tecnologia ao racismo estrutural e à história da vigilância no Brasil, oferecendo uma base intelectual robusta para entender por que o erro acontece, porém a linguagem é voltada para pesquisadores, o que pode tornar a leitura mais lenta e difícil para quem busca uma explicação rápida ou puramente técnica do funcionamento dos algoritmos. Em minha opinião essa obra é essencial para a discussão do assunto em questão, pois retira o racismo algorítmico do campo da falha técnica e o coloca no campo do conflito de poder ao demonstrar que a tecnologia é desenhada para ver melhor quem se parece com seus criadores, o autor prova que a neutralidade algorítmica é uma ferramenta de manutenção de privilégios. Embora seja uma leitura densa e acadêmica, considero-a a fonte mais corajosa, pois não sugere apenas "ajustar o código", mas sim questionar quem detém o direito de vigiar e quem está sendo invisibilizado pela "máquina branca".

Pele negra, máquinas brancas

Este episódio de podcast investiga as consequências reais e muitas vezes trágicas do racismo algorítmico no Brasil. Através de entrevistas com especialistas como Nina da Hora e Tarcízio Silva, a obra foca em como sistemas de reconhecimento facial, vendidos como soluções de segurança pública, têm levado à prisão injusta de pessoas negras. O episódio denuncia o "colonialismo científico", onde tecnologias desenvolvidas no Hemisfério Norte (muitas vezes testadas em bases de dados brancas) são importadas e aplicadas sem critério em uma realidade brasileira marcada pelo racismo estrutural, transformando a IA em uma ferramenta de vigilância seletiva. Diferente das fontes teóricas, o podcast dá voz e rosto às vítimas, mostrando que o "erro algorítmico" não é apenas uma estatística, mas uma violação de direitos fundamentais e liberdade, porém por se tratar de um podcast narrativo longo, ele se mostra menos eficiente para quem precisa de uma consulta rápida a termos técnicos ou definições diretas.

Minha análise sobre o episódio do Ciência Suja é que ele serve como um "choque de realidade", pois retira o racismo algorítmico do campo abstrato dos dados e o coloca no campo brutal da justiça criminal. O podcast prova que a tecnologia está sendo usada para higienizar o arbítrio policial sob uma máscara de modernidade. Em última análise, a obra é um alerta urgente de que, enquanto a tecnologia for tratada como infalível e neutra, ela continuará sendo uma arma de opressão que automatiza injustiças históricas com uma eficiência sem precedentes.

Publicar ou perecer

O episódio aborda a crise na escrita dos artigos científicos na atualidade. Essa queda de qualidade se deve a pressão colocada em cima dos pesquisadores para publicar artigos, pois eles dependem dessas publicações para obter financiamento. Esse cenário gera artigos não muito confiáveis, nomeados no episódio de “meia-boca” que muitas vezes são usados até em revistas predatórias, fazendo com que se tenha uma descredibilidade quanto à qualidade e veracidade dos artigos e da ciência atual. Em meio a isso tudo o podcast alerta o público sobre essas pesquisas com possíveis manipulações de resultados e sugerem algumas soluções para diminuir ou até mesmo evitar que isso ocorra.

Na minha opinião esses artigos além de proporcionarem uma grande confusão, em casos de um pesquisador, por exemplo, achar um desses artigos e basear sua pesquisa nele e acabar gerando mais um artigo com possíveis erros, eles também fazem com que a ciência perca credibilidade quanto a qualidade das pesquisas. Quanto a solução, eu concordo em muito com a de profissionalizar as pessoas que dependem das pesquisas, pois faria com que esses pesquisadores pudessem focar mais na qualidade dos artigos do que em quantidade, o que geralmente acontece ao contrário pela necessidade de uma renda através dos artigos.

Deepfakes, Phrenology, Surveillance, and More! A Taxonomy of AI Privacy Risks (CHI 2024)

O artigo aborda os riscos à privacidade em produtos e serviços gerados pela IA atualmente, baseando-se em 321 casos reais documentados para construir uma taxonomia desses riscos. Os autores descobriram que, em 93% dos incidentes analisados, a IA criou ou agravou riscos à privacidade, identificando 12 tipos distribuídos em quatro categorias: coleta, processamento, disseminação de dados e invasão. Entre os riscos criados pela IA estão a identificação automática mesmo com imagens de baixa qualidade, a previsão de comportamentos futuros por agregação de dados, a frenologia/fisiognomia (inferir características como orientação sexual ou etnia a partir da aparência física), a exposição via deepfakes e a distorção por áudio e vídeo falsos. Já os riscos agravados incluem vigilância em escala ampliada, uso secundário de dados sem consentimento, exclusão de indivíduos do controle sobre seus dados, insegurança com vazamento de informações, divulgação indevida de inferências sensíveis, maior acessibilidade a dados pessoais por datasets abertos e intrusão por dispositivos inteligentes.

Levando em consideração todos esses dados e riscos oferecidos pela IA seria necessário uma abordagem específica para ela, de forma que a privacidade de todos seja garantida, principalmente levando em consideração o uso de dados pessoais e a imagem de pessoas, o que pode dar liberdade para que vários crimes sejam cometidos.

The era of blind faith in big data must end

Cathy O'Neil argumenta que o fim da fé cega em big data é necessário, pois os algoritmos, ao contrário do que se imagina, não são objetivos ou científicos, mas sim opiniões incorporadas em código. Ela criou o termo "armas de destruição matemática" para descrever modelos que são secretos, importantes e prejudiciais, os quais decidem desde quem consegue um empréstimo até quem é contratado, frequentemente reforçando preconceitos humanos e automatizando práticas passadas injustas. Para combater esse problema, O'Neil propõe uma auditoria algorítmica de quatro etapas:

verificar a integridade dos dados (que podem conter vieses históricos), questionar a definição de sucesso usada no modelo, analisar a taxa de erros e quem é afetado por eles, e considerar os ciclos de feedback que podem criar profecias auto realizáveis.

Na minha visão Cathy está correta em considerar que os algoritmos são neutros apenas porque usam matemática, pois o grande volume de dados utilizado por eles pode ter sido, e muitas vezes é, de origem humana, ou seja, pode conter vários tipos de preconceitos dentro desses dados que passam por tais algoritmos. Quanto às etapas proposta por ela, apesar de parecer exagerado, eu concordo com elas, principalmente a primeira, na qual se analisa o dado principalmente se for em questão ética.

Saving Face: Investigating the Ethical Concerns of Facial Recognition Auditing

O artigo investiga os dilemas éticos envolvidos na auditoria de sistemas de reconhecimento facial, mostrando que mesmo tentativas bem-intencionadas de avaliar vieses podem acabar prejudicando as populações que se pretende proteger. Os autores desenvolveram um benchmark chamado CelebSET (com 80 celebridades divididas por gênero e tom de pele) e avaliaram APIs comerciais da Microsoft, Amazon e Clarifai, confirmando que há disparidades significativas de desempenho, grupos mais escuros e mulheres tiveram piores resultados, e a Clarifai, que nunca havia sido auditada publicamente, apresentou a maior diferença (19,10% entre homens brancos e mulheres negras na classificação de gênero). A partir dessa experiência, os autores identificam cinco preocupações éticas: 1 a auditoria tem escopo limitado e pode levar empresas a melhorar apenas as tarefas específicas que foram expostas, ignorando outros problemas; 2 é preciso auditar não só os resultados, mas também o processo de desenvolvimento (ex.: a lista de celebridades que a API reconhece já carrega viés, a Clarifai tem 74% de brancos); 3 há tensão entre representatividade e privacidade, coletar mais dados de grupos sub-representados aumenta os riscos de privacidade justamente para eles; 4 a abordagem por grupos (ex.: "mulher negra") não capta completamente a interseccionalidade, podendo mascarar vieses relacionados à idade ou outras características; 5 transparência pode levar empresas a "overfittarem" o benchmark ou a retirarem suas APIs do acesso público, dificultando futuras auditorias. A conclusão é que auditorias como a do CelebSET são necessárias, mas insuficientes, servem para expor pontos cegos, não para validar que um sistema é seguro ou justo, e jamais deveriam ser usadas sozinhas como justificativa para liberar ou banir o uso da tecnologia.

Ao analisar os dados e as problemáticas apontadas pelo artigo, eu acho que realmente existe um risco em analisar dados de forma errada, não considerando possíveis falhas no levantamento, como o caso de ignorar outras características físicas que poderiam alterar o resultado da pesquisa, como a idade, igual é citado no artigo. Essa análise incorreta, como no caso do artigo, pode levar à descredibilidade de algo, no caso do artigo foi uma ferramenta, ou a falta de um complemento na análise leva a soluções erradas ou incompletas da ferramenta, como o caso de desconsiderar a idade das pessoas.

Unmasking the bias in facial recognition algorithms

A autora relata sua experiência como aluna do MIT, quando precisou usar uma máscara branca para que um software de análise facial detectasse seu rosto, algo que não acontecia com pessoas de pele mais clara. Ela introduz o conceito de "power shadows" (sombras de poder) : vieses e exclusões sistêmicas da sociedade que se refletem nos dados usados para treinar IA. Como exemplo, cita o caso da Amazon, que criou um modelo de triagem de currículos treinado com base em funcionários anteriores bem avaliados, majoritariamente homens, fazendo com que o sistema passasse a filtrar currículos que continham palavras associadas a mulheres. No caso do reconhecimento facial, Buolamwini analisou datasets considerados referência, incluindo um criado por um órgão governamental que pretendia ser diverso, mas que ainda assim tinha mais de 80% de indivíduos de pele clara e era majoritariamente masculino. Ela explica que isso ocorre porque os datasets foram construídos a partir de figuras públicas (como parlamentares), que já refletem desigualdades históricas: patriarcado (menos

mulheres no poder), colonialismo e supremacia branca (países ex-colonizados mantiveram estruturas de poder que favorecem pessoas mais claras), além do colorismo (valorização social da pele mais clara dentro de uma mesma raça). Também critica a coleta de imagens baseada em disponibilidade online, pessoas com mais atenção da mídia aparecem mais, e essas são frequentemente mais claras. Buolamwini conclui que os "padrões ouro" da indústria não representam a humanidade como um todo, gerando uma falsa sensação de progresso universal, e defende que é preciso intencionalidade e novos métodos para construir datasets e avaliar tecnologias de reconhecimento facial.

Analisando os dados e as problemáticas apontadas por Buolamwini, eu acho que ela está correta ao afirmar que os datasets refletem as desigualdades da sociedade, o que ela chama de "sombras de poder". O problema não é apenas técnico (falta de dados diversos), mas também político e histórico: se os dados vêm de um mundo onde homens brancos sempre tiveram mais poder e visibilidade, a IA vai aprender e reproduzir isso. O caso da Amazon é exemplar: o algoritmo não "decidiu" ser sexista por maldade; ele apenas aprendeu com decisões humanas passadas que favoreciam homens. Isso mostra que dados não são neutros, eles carregam preconceitos históricos. Concordo com ela que não adianta criar datasets "tecnicamente diversos" se o método de coleta continuar dependendo de figuras públicas ou de disponibilidade online, pois isso apenas replica as mesmas exclusões. A solução passa por intencionalidade: é preciso pensar ativamente em quem está sendo deixado de fora e corrigir isso na fonte, não apenas nos algoritmos depois.

On the Dangers of Stochastic Parrots: Can Language Models Be Too Big?

O artigo questiona a corrida por modelos de linguagem cada vez maiores (como GPT-3, BERT e Switch-C), argumentando que essa busca desenfreada por escala traz riscos graves que vão além do desempenho em benchmarks. Os autores identificam quatro categorias principais de problemas: 1 custos ambientais e financeiros, treinar um único modelo grande pode emitir mais CO₂ do que um voo transatlântico, e esses custos recaem desproporcionalmente sobre comunidades marginalizadas que menos se beneficiam da tecnologia; 2 dados de treinamento incompreensíveis, conjuntos enormes coletados da internet super-representam visões hegemônicas (brancos, homens, jovens), excluem vozes marginalizadas e codificam vieses racistas, sexistas e capacitistas, criando uma "dívida de documentação" impossível de resolver post hoc; 3 ilusão de compreensão, modelos não entendem linguagem, apenas manipulam formas estatísticas ("papagaios estocásticos"), e os pesquisadores são levados por um caminho equivocado ao confundir fluência com significado; 4 riscos concretos de dano, esses modelos podem gerar textos que reproduzem e amplificam estereótipos, discurso de ódio, desinformação e até extremismo, além de vazarem dados pessoais do treinamento. Como solução, os autores propõem: priorizar a eficiência energética como métrica de avaliação; investir em curadoria cuidadosa e documentação de datasets, não apenas em escala; usar técnicas como "pré-mortem" e design sensível a valores para antecipar danos antes de desenvolver o modelo; e, fundamentalmente, reconhecer que criar sistemas que imitam humanos de forma convincente é uma "linha vermelha" na ética da IA, exigindo reflexão profunda sobre benefícios, riscos e alternativas que não dependam de modelos cada vez maiores.

Analisando os dados e as problemáticas apontadas pelo artigo, eu acho que realmente existe um risco em focar apenas no tamanho dos modelos de linguagem sem considerar os impactos ambientais, os vieses dos dados e a falsa sensação de que esses modelos realmente "entendem" a linguagem. O artigo mostra que dados coletados da internet, por serem de origem humana, carregam preconceitos históricos, racismo, sexismo, capacitismo, e que modelos maiores apenas amplificam esses problemas em vez de resolvê-los. Além disso, o custo ambiental é ignorado pela maioria dos pesquisadores, e esse custo afeta primeiro quem já é marginalizado. Eu concordo com os autores quando dizem que criar sistemas que imitam humanos de forma convincente é perigoso, pois as pessoas tendem a atribuir significado e intenção onde não existe, gerando riscos reais como desinformação, discriminação automatizada e até recrutamento extremista. A solução proposta, priorizar curadoria cuidadosa de dados, documentação transparente e eficiência energética, me parece mais sensata do que simplesmente buscar o próximo recorde de parâmetros. No fim, o artigo me convenceu de que maior nem sempre é melhor, e que a comunidade de IA precisa repensar suas prioridades.