

Lista 2

Pedro Henrique Lopes de Melo
Ciência da Computação — Inteligência Artificial

Link para o código desenvolvido

Questão 03 — Questao03_Titanic_arvore_decisao.ipynb (Google Colab, acesso liberado para qualquer pessoa com o link):

- https://colab.research.google.com/drive/1sXgBlqRt0w5K9zjtJT5NHswxPJgc_wD?usp=sharing

A Questão 02 utiliza, sem modificações, o notebook AD-Restaurante - codifica treina e avalia.ipynb disponibilizado no CANVAS. A Questão 01 foi entregue separadamente. Este documento traz as Questões 02, 03 e 04.

Questão 02 — Base "Restaurante"

O código usa LabelEncoder nos atributos binários e ordinais, OneHotEncoder no atributo Tipo (nominal), holdout com test_size = 0,20 e random_state = 23 (9 instâncias de treino, 3 de teste) e DecisionTreeClassifier com criterion = "entropy". Codificações relevantes para ler a árvore: Preço R = 0, RR = 1, RRR = 2; Tempo 0-10 = 0, 30-60 = 1, >60 = 2, out/30 = 3; Não = 0 e Sim = 1 nos binários.

2.1) Qual a árvore obtida?

Profundidade 3, com 3 nós de decisão e 4 folhas, todas puras:

```
| --- Fome <= 0.50                (Fome = Nao)
| | --- class: Nao
| --- Fome > 0.50                (Fome = Sim)
| | --- Preço <= 1.50            (Preço = R ou RR)
| | | --- class: Sim
| | --- Preço > 1.50            (Preço = RRR)
| | | --- Tempo <= 1.50          (Tempo = 0-10 ou 30-60)
| | | | --- class: Sim
| | | --- Tempo > 1.50          (Tempo = >60 ou out/30)
| | | | --- class: Nao
```




Figura 1 — Árvore gerada pelo scikit-learn para a base Restaurante.

A raiz é Fome, e não Cliente como no cálculo manual da Questão 01. A diferença ocorre porque a Questão 01 usa as 12 instâncias e aqui a árvore é treinada com apenas 9: nesse subconjunto, "Fome = Não" separa perfeitamente 4 exemplos da classe "Não" e passa a ter o maior ganho de informação. É um exemplo da instabilidade das árvores em bases muito pequenas.

2.2) Recall, precision e F1-Score

Classe	Precision	Recall	F1-Score	Suporte
Não esperar	0,00	0,00	0,00	1
Esperar	0,50	0,50	0,50	2
Acurácia global	—	—	0,33	3

Das 3 instâncias de teste o modelo acertou 1. Para "Não esperar" ele fez uma única previsão e errou (VP = 0), logo precision = recall = F1 = 0. Para "Esperar" fez 2 previsões, acertou 1 (precision = 1/2) e recuperou 1 das 2 instâncias reais (recall = 1/2), logo F1 = 0,50.

A acurácia de 33% não indica falha do algoritmo, e sim da metodologia: o teste tem apenas 3 instâncias (cada erro vale 33 pontos percentuais), o split não foi estratificado e a árvore acerta 100% no treino contra 33% no teste — overfitting clássico. Para uma base de 12 exemplos o correto seria validação cruzada estratificada, não holdout.

2.3) Quais as regras obtidas?

R1: SE Fome = Nao
ENTAO NAO ESPERAR

R2: SE Fome = Sim E Preco IN {R, RR}
ENTAO ESPERAR

R3: SE Fome = Sim E Preco = RRR E Tempo IN {0-10, 30-60}
ENTAO ESPERAR

R4: SE Fome = Sim E Preço = RRR E Tempo IN {>60, out/30}
ENTAO NAO ESPERAR

2.4) Qual a qualidade de cada regra?

A qualidade é medida por cobertura (fração de instâncias que satisfazem o antecedente) e confiança (fração das cobertas em que o consequente está correto). Como todas as folhas são puras, a confiança no treino é 100% em todas — o que apenas confirma o overfitting. Medindo também na base completa de 12 instâncias:

Regra	Cobertura (treino / base)	Confiança (treino / base)
R1 — Fome = Não → Não esperar	4/9 (44%) / 5/12 (42%)	100% / 80%
R2 — Fome=Sim ∧ Preço ∈ {R,RR} → Esperar	3/9 (33%) / 5/12 (42%)	100% / 80%
R3 — ...Preço=RRR ∧ Tempo curto → Esperar	1/9 (11%) / 1/12 (8%)	100% / 100%
R4 — ...Preço=RRR ∧ Tempo longo → Não esperar	1/9 (11%) / 1/12 (8%)	100% / 100%

- R1 e R2 são as regras úteis: juntas cobrem 10 das 12 instâncias (83%) e mantêm 80% de confiança fora do treino.
- R3 e R4 têm confiança de 100%, mas cobrem 1 instância cada. Confiança apoiada em um único exemplo não generaliza — são exatamente os ramos que uma poda eliminaria.

Questão 03 — Padrão de sobrevivência no TITANIC

3.1) Visualização da base

A base tem 1.309 instâncias e 14 atributos. A classe survived está moderadamente desbalanceada: 61,8% não sobreviveram e 38,2% sobreviveram. Valores ausentes: cabin 77,5%, body 90,8%, boat 62,9%, home.dest 43,1%, age 20,1%, embarked 2 registros e fare 1 registro.




Figura 2 — Sobrevivência por sexo, por classe do bilhete e distribuição da idade.

As distribuições já antecipam o padrão: 72,7% das mulheres sobreviveram contra 19,1% dos homens; e a taxa cai de 61,9% na 1ª classe para 25,5% na 3ª.

Vazamento de dados: boat e body registram informação posterior ao naufrágio. Entre quem tem boat preenchido, 98,1% sobreviveram; entre quem tem body preenchido, 0% sobreviveu. Mantê-los daria acurácia de quase 100% sem descobrir padrão algum, porque o modelo estaria apenas lendo a resposta. Foram removidos, junto com home.dest, pelo mesmo motivo.

3.2) Codificação de cada atributo

Atributo	Decisão	Justificativa
boat, body, home.dest	removidos	vazamento de dados
ticket	removido	código de altíssima cardinalidade, sem semântica
name	vira "título"	o nome é identificador único, mas o título (Mr, Mrs, Miss, Master) resume sexo, faixa etária e status; extraído por regex em 5 categorias
sex	binário (0 = fem., 1 = masc.)	nominal com 2 categorias
pclass	ordinal (1 < 2 < 3)	a ordem é real, então o inteiro é adequado
embarked, título	OneHotEncoder	nominais sem ordem natural; embarked imputado pela moda (S)
age	numérico, mediana por título	20,1% de ausentes; a mediana por título preserva a diferença entre Master (crianças) e Mr (adultos)
fare	numérico, mediana por pclass	distribuição assimétrica e dependente da classe
cabin	vira "tem_cabine" (0/1)	77,5% ausente, mas a ausência é informativa: com cabine 65,4% sobreviveram, sem cabine 30,3%
sibsp, parch	numéricos + tam_familia e sozinho	são contagens; os derivados capturam o efeito não-linear do tamanho do grupo

Árvores de decisão não exigem normalização, portanto nenhum scaler foi aplicado.

3.3) Regras obtidas e padrão de mortalidade

Holdout estratificado 70/30 (916 treino, 393 teste), criterion = "entropy". A profundidade foi escolhida por validação cruzada de 10 folds: max_depth = 3 obteve 0,810 contra 0,792 da árvore sem limite, que decorava o treino (0,846 no treino, 0,791 no teste). O modelo final tem 80,7% de acurácia no teste.

Classe	Precision	Recall	F1-Score	Suporte
Não sobreviveu	0,833	0,860	0,846	243
Sobreviveu	0,761	0,720	0,740	150
Acurácia global	—	—	0,807	393




Figura 3 — Árvore final (entropia, max_depth = 3). Importância: sexo 0,62; pclass 0,16; tem_cabine 0,08.

As 8 folhas geram 8 regras. A confiança no teste é a medida honesta da qualidade, por ser calculada em dados nunca vistos:

Regra	Cobertura (teste)	Confiança (teste)
R1 — mulher, 1ª/2ª classe, tarifa ≤ 31,68 → SOBREVIVEU	9,7%	92,1%
R2 — mulher, 1ª/2ª classe, tarifa > 31,68 → SOBREVIVEU	10,9%	95,3%
R3 — mulher, 3ª classe, família ≤ 4 → SOBREVIVEU	14,2%	50,0%
R4 — mulher, 3ª classe, família ≥ 5 → NÃO SOBREVIVEU	3,1%	100,0%
R5 — homem, sem cabine, idade ≤ 14 → NÃO SOBREVIVEU	4,1%	56,2%
R6 — homem, sem cabine, idade > 14 → NÃO SOBREVIVEU	47,1%	87,0%
R7 — homem, com cabine, título = Master → SOBREVIVEU	1,3%	80,0%

Regra	Cobertura (teste)	Confiança (teste)
R8 — homem, com cabine, título = Mr → NÃO SOBREVIVEU	9,7%	71,1%

Padrão de mortalidade encontrado:

- O sexo é o fator dominante (62% da importância). R6 e R8 juntas cobrem 57% da base e predizem morte para homens adultos com 87% e 71% de confiança.
- A classe modula dentro de cada sexo: mulher de 1ª ou 2ª classe sobreviveu com 92% a 95% de confiança (R1, R2); mulher de 3ª classe caiu para 50% (R3), o mesmo que um lançamento de moeda.
- "Mulheres e crianças primeiro" só valeu integralmente nas classes altas: R7 salva os meninos com cabine registrada, enquanto R5 mostra que meninos sem cabine morreram como os adultos.
- R4 é contraintuitiva e confiável: mulheres da 3ª classe em famílias de 5 ou mais morreram em 100% dos casos do teste — famílias numerosas provavelmente não conseguiram se deslocar juntas até os botes.

Em resumo: sobreviveu quem era mulher ou criança de classe alta; morreu quem era homem adulto, e morreu ainda mais quem era pobre.

Questão 04 — Árvore da base Iris

A árvore usa apenas petallength e petalwidth; os atributos de sépala não aparecem em nenhum nó, portanto seus valores nas instâncias de teste são irrelevantes.

Instância	Percurso na árvore	Classe
1 (PL 3.46, PW 0.87)	$PL > 2.35 \rightarrow PW \leq 1.75 \rightarrow PL \leq 4.95$	Iris-versicolor
2 (PL 1.67)	$PL \leq 2.35$ (folha pura, $n = 39$)	Iris-setosa
3 (PL 2.56, PW 2.34)	$PL > 2.35 \rightarrow PW > 1.75 \rightarrow PL \leq 4.85$	Iris-versicolor
4 (PL 6.67, PW 2.34)	$PL > 2.35 \rightarrow PW > 1.75 \rightarrow PL > 4.85$	Iris-virginica

Alternativa correta: (c) Iris_Versicolor, Iris_Setosa, Iris_Versicolor, Iris_Virgínica.

A Instância 3 cai na folha $value = [0, 1, 1]$ com $gini = 0,5$, ou seja, 2 exemplos empatados: a predição "versicolor" vem apenas do critério de desempate do scikit-learn e não tem confiança estatística. Já a Instância 4 cai em folha pura com 39 exemplos. As alternativas (a), (b) e (d) erram já na Instância 1 ou 2, e a (e) erra a Instância 4, pois $petallength = 6,67$ ultrapassa o limiar $4,85$ e leva à folha de virginica.