

Lista #3

Curso: Ciência da Computação

Disciplina: Inteligência Artificial

Prof^a. Cristiane Neri Nobre

Data de entrega: 20/09

Valor: 2 pontos

Questão 01

Baseado nos códigos já desenvolvidos para resolver o problema do TITANIC, encontre o padrão de pessoas que sobreviveram ao desastre do TITANIC, que matou mais de 1.500 pessoas em 1912. A base de dados do TITANIC está disponível no CANVAS.

Etapas obrigatórias:

1. **Pré-processamento:** a) **Imputação de dados ausentes:** para os atributos com valores ausentes, compare **dois métodos de imputação:**

- **KNN Imputer** (KNNImputer do scikit-learn)
- **MissForest** (imputação baseada em Random Forest, disponível via biblioteca missingpy ou IterativeImputer do scikit-learn configurado com estimador baseado em árvores)

Para cada método, avalie o impacto da escolha sobre a distribuição dos dados imputados (ex.: compare a distribuição do atributo antes e depois da imputação) e justifique qual método foi adotado para seguir com a modelagem. b) **Balanceamento de classes:** caso a variável-alvo esteja desbalanceada, aplique e compare **duas técnicas de balanceamento:**

- **SMOTE** (Synthetic Minority Oversampling Technique), **Borderline-SMOTE**, **SMOTE-Tomek**, **SMOTE-ENN** ou **ADASYN**
- **RandomUnderSampling**

Aplique o balanceamento **apenas no conjunto de treino** (nunca no conjunto de teste), e compare a distribuição das classes antes e depois de cada técnica.

2. **Modelagem com Árvore de Decisão:**

- a) Treine um classificador de Árvore de Decisão para prever a sobrevivência dos passageiros.
- b) Otimize os hiperparâmetros do modelo (ex.: max_depth, min_samples_split, min_samples_leaf, criterion) utilizando **dois otimizadores de hiperparâmetros diferentes** dentre as opções abaixo:

- Random Search (RandomizedSearchCV)

- Otimização Bayesiana (ex.: Optuna, Bayesian Optimization, ou BayesSearchCV do scikit-optimize)
- c) Reporte, para cada otimizador, os melhores hiperparâmetros encontrados e o tempo de execução da busca.
- d) Forneça as **regras obtidas pela árvore de decisão** (extraídas do modelo já com os hiperparâmetros otimizados) que mostrem o padrão de sobrevivência/mortalidade dos passageiros. Utilize `export_text`, `plot_tree` ou ferramenta equivalente para visualizar/extrair as regras.

3. Modelagem com Random Forest:

- a) Treine um classificador Random Forest para o mesmo problema.
- b) Repita o processo de otimização de hiperparâmetros (ex.: `n_estimators`, `max_depth`, `min_samples_split`, `max_features`) utilizando os **mesmos dois otimizadores** escolhidos na etapa anterior, para permitir uma comparação justa entre os métodos de busca.
- c) Reporte os melhores hiperparâmetros encontrados por cada otimizador e o tempo de execução da busca.

4. Avaliação e comparação dos resultados:

- a) Avalie os dois modelos (Árvore de Decisão e Random Forest, cada um já com hiperparâmetros otimizados) utilizando métricas de classificação (acurácia, precisão, recall e F1-score). Avalie os modelos treinados com **cada uma das combinações de imputação e balanceamento** exploradas nos itens 2.b e 2.c (ex.: KNN Imputer + SMOTE, KNN Imputer + variação escolhida, MissForest + SMOTE, MissForest + variação escolhida).
- b) Compare o desempenho da Árvore de Decisão com o do Random Forest. Qual modelo generaliza melhor?
- c) Compare os dois otimizadores de hiperparâmetros utilizados: houve diferença significativa entre os melhores hiperparâmetros encontrados? Qual otimizador foi mais eficiente em termos de tempo de execução vs. qualidade da solução encontrada?
- d) Compare os métodos de imputação (KNN Imputer vs. MissForest): houve diferença relevante no desempenho final dos modelos? Qual método preservou melhor a distribuição original dos dados?
- e) Compare as técnicas de balanceamento (SMOTE vs. a variação escolhida): qual técnica produziu melhor equilíbrio entre precisão e recall para a classe minoritária (sobreviventes ou não sobreviventes, conforme o desbalanceamento identificado)?
- f) Discuta: as regras extraídas da Árvore de Decisão continuam interpretáveis da mesma forma no Random Forest? Por que o Random Forest tende a ter melhor desempenho preditivo, mas pior interpretabilidade, em comparação com uma única Árvore de Decisão?

Entregáveis:

- Notebook com todo o código, análises e visualizações;

- Tabela comparativa dos métodos de imputação (KNN Imputer vs. MissForest), incluindo o efeito sobre a distribuição dos dados;
- Tabela comparativa das técnicas de balanceamento (SMOTE vs. variação escolhida), incluindo a distribuição de classes antes/depois;
- Tabela comparativa consolidando os hiperparâmetros encontrados pelos dois otimizadores, para os dois modelos;
- Tabela comparativa de métricas de desempenho (Árvore de Decisão vs. Random Forest, para cada combinação de imputação/balanceamento testada);
- Texto de conclusão (mínimo 1 parágrafo) discutindo os resultados obtidos nos itens 5.b a 5.f.

Material de apoio:

- <https://www.encyclopedia-titanica.org/titanic-survivors/>
- <https://www.kaggle.com/competitions/titanic/rules>