

Lista 3

Pedro Henrique Lopes de Melo
Ciência da Computação — Inteligência Artificial

Link para o código desenvolvido

Notebook `Lista3_IA_Titanic_AD_RF.ipynb` (Google Colab, acesso liberado para qualquer pessoa com o link):

- <https://colab.research.google.com/drive/13TsV-Fd7gyBmaZSYCPnt3u2Sez8Orhqi?usp=sharing>

Esta lista continua a Questão 03 da Lista 2, com a mesma base *titanic completo.csv* (1.309 passageiros, 14 atributos), a mesma codificação e o mesmo holdout estratificado 70/30 com `random_state = 23` (916 passageiros de treino e 393 de teste). A codificação remove *boat*, *body* e *home.dest* por vazamento de dados, extrai *título* do nome e deriva *tem_cabine*, *tam_familia* e *sozinho*. O conjunto de teste nunca participa da imputação, do balanceamento nem da otimização: todos esses passos são ajustados apenas no treino.

Foram treinados 24 modelos: 2 algoritmos (Árvore de Decisão e Random Forest), 2 imputações (KNN Imputer e MissForest), 3 opções de balanceamento (sem balanceamento, SMOTE-NC e RandomUnderSampler) e 2 otimizadores (Random Search e Otimização Bayesiana com Optuna). O caso sem balanceamento serve de referência para medir o efeito real das técnicas. As saídas do notebook foram geradas com `scikit-learn 1.9.1`, `imbalanced-learn 0.14.2` e `optuna 5.0.0` em uma CPU de 8 núcleos, com 4 processos paralelos. Em outra máquina, como o Colab, os tempos absolutos mudam; com as mesmas versões as métricas se repetem, porque todas as sementes aleatórias são fixas.

Questão 01 — Padrão de sobrevivência no TITANIC

1.a) Imputação de dados ausentes

Os atributos com valores ausentes são *age* (263 registros, 20,1%), *embarked* (2) e *fare* (1). *cabin* (77,5% ausente) não é imputado: a ausência é informativa e já vira o indicador *tem_cabine*. Os dois métodos recebem todos os atributos codificados; *embarked* entra como código (S = 0, C = 1, Q = 2), arredondado depois da imputação.

- **KNN Imputer** (`KNNImputer`, `k = 5`): cada valor ausente recebe a média dos 5 passageiros mais próximos. Os atributos são escalados para `[0, 1]` antes do cálculo da distância e revertidos depois; sem a escala, *fare* (0 a 512) dominaria a distância euclidiana.
- **MissForest** (`IterativeImputer` com `RandomForestRegressor` de 100 árvores, até 10 iterações): cada atributo com ausentes é previsto por uma Random Forest treinada nos demais atributos, e o ciclo se repete até estabilizar. A biblioteca `missingpy` não funciona com as versões atuais do `scikit-learn`, por isso foi usada a alternativa indicada no enunciado.
- A **mediana por título**, estratégia da Lista 2, aparece apenas como referência.

Além das estatísticas descritivas e dos testes de distribuição (Kolmogorov-Smirnov e distância de Wasserstein, sempre contra as 742 idades observadas no treino), foi medido o **erro de imputação mascarado**: 20% das idades conhecidas do treino são escondidas, imputadas e comparadas com o valor real (MAE e RMSE, média de 3 repetições).

Atributo age (treino)	Original (observado)	KNN Imputer	MissForest	Mediana/título (Lista 2)
Média / desvio padrão	30,08 / 14,07	29,86 / 13,28	29,89 / 13,24	29,72 / 12,97
Q1 / mediana / Q3	21,0 / 29,0 / 38,0	22,0 / 28,0 / 36,2	22,0 / 28,4 / 36,9	22,0 / 30,0 / 36,0
Assimetria	0,333	0,326	0,336	0,370
Média / desvio só dos imputados	— / —	28,95 / 9,15	29,07 / 8,79	28,18 / 6,17
KS vs. original (p-valor)	0,000 (1,000)	0,064 (0,067)	0,036 (0,662)	0,060 (0,099)
Distância de Wasserstein	0,000	0,844	0,909	1,481
corr(age, pclass) / corr(age, parch)	-0,438 / -0,141	-0,446 / -0,126	-0,449 / -0,118	-0,418 / -0,114
MAE mascarado ($\pm$ desvio)	—	8,68 ($\pm$ 0,25)	8,55 ($\pm$ 0,13)	9,00 ($\pm$ 0,40)
RMSE mascarado	—	11,28	11,24	11,93
Tempo de ajuste + transformação (s)	—	0,06	1,84	—

Tabela 1 — Comparação dos métodos de imputação sobre a distribuição de age (conjunto de treino, 742 observadas e 174 imputadas).




Figura 1 — Distribuição de age antes x depois da imputação, valores imputados e idades imputadas por título.

Efeito sobre a distribuição. Os dois métodos preservam a média (29,9 contra 30,1 da original) e a correlação de *age* com *pclass* (-0,45 contra -0,44), e ambos reduzem o desvio padrão de 14,07 para cerca de 13,25. Essa redução é esperada: um valor estimado a partir de vizinhos ou de uma floresta é uma média condicional e fica sempre mais perto do centro que um valor real. As diferenças aparecem nos detalhes:

- O **MissForest** tem a menor estatística KS (0,036, $p = 0,66$), contra 0,064 ($p = 0,067$) do KNN. A distribuição completa depois do MissForest é estatisticamente indistinguível da original, e a do KNN fica no limite da significância. O MissForest também mantém a assimetria (0,336 contra 0,333 da original), espalha os valores imputados de forma mais contínua (Figura 1, centro) e tem o menor erro mascarado: MAE de $8,55 \pm 0,13$ anos, contra $8,68 \pm 0,25$ do KNN.
- O **KNN Imputer** tem uma distância de Wasserstein um pouco menor (0,84 contra 0,91) e é muito mais rápido (0,06 s contra 1,8 s). Por outro lado, concentra os imputados em poucos valores (pico em torno de 25 anos), porque a média de 5 vizinhos com o mesmo título e a mesma classe se repete.
- A **mediana por título** (Lista 2) é a pior em quase todos os critérios: coloca a maior parte dos imputados em um único valor por título (pico em 30 anos na Figura 1), o desvio dos imputados cai para 6,17 e o MAE sobe para 9,00.

Nos dois ausentes de *embarked* (Amelie Icard e Martha Stone, 1ª classe, mesma cabine e tarifa de 80), os dois métodos imputaram C (Cherbourg). Segundo a Encyclopedia Titanica, as duas embarcaram em Southampton (S), então os dois métodos erraram da mesma forma, com efeito desprezível sobre 2 registros. No único *fare* ausente (3ª classe, no teste), o KNN imputou 8,18 e o MissForest 6,74, ambos valores típicos da 3ª classe.

Método adotado: MissForest. Foi o que melhor preservou a forma da distribuição original (menor KS e assimetria mantida) e o que mais acertou idades reais escondidas, com erro também mais estável entre as repetições. O custo de 1,8 s é irrelevante nesta base. Mesmo assim, o item 4 avalia as duas imputações, como o enunciado pede.

1.b) Balanceamento de classes

No treino há 566 não sobreviventes e 350 sobreviventes (61,8% e 38,2%, razão de 1,62 : 1). É um desbalanceamento moderado, com **sobreviveu (1)** como classe minoritária. Foram comparadas duas técnicas, mais o caso sem balanceamento como referência:

- **SMOTE, na versão SMOTE-NC:** cria exemplos sintéticos da classe minoritária interpolando cada exemplo com um de seus 5 vizinhos mais próximos. O SMOTE clássico interpola *todos* os atributos, e nesta base isso cria passageiros impossíveis: 65,7% dos 216 sintéticos têm algum atributo nominal fracionário, 32,4% com *sexo* fracionário (por exemplo 0,37) e 19,4% com *pclass* fracionário. Em um teste preliminar com o SMOTE clássico, a árvore otimizada criou cortes como *sexo* $\leq 0,996$, que só separam exemplos sintéticos, e uma das regras teve só 17% de confiança no teste. Por isso foi usado o **SMOTE-NC** (SMOTENC do imbalanced-learn), a variante do SMOTE para dados mistos definida no próprio artigo original (Chawla et al., 2002, seção 6.1). Ele interpola apenas os atributos contínuos e, nos categóricos (*pclass*, *sexo*, *titulo*, *embarked*, *tem_cabine* e *sozinho*), usa o valor mais frequente entre os vizinhos. Com o SMOTE-NC, nenhum exemplo sintético tem categoria inválida.
- **RandomUnderSampler:** descarta aleatoriamente 216 não sobreviventes (38% da classe majoritária) até as duas classes ficarem com 350 exemplos.

O balanceamento é aplicado **somente ao treino**. Nas buscas de hiperparâmetros ele fica dentro de um imblearn.Pipeline, então em cada fold da validação cruzada só a parte de treino do fold é reamostrada e a parte de validação mantém a proporção real. O conjunto de teste (243 e 150) nunca é reamostrado.

Conjunto / técnica	Não sobreviveu (0)	Sobreviveu (1)	Total	% sobreviveu	Razão 0:1
Treino — antes (original)	566	350	916	38,2%	1,62
Treino — depois do SMOTE-NC	566	566	1132	50,0%	1,00
Treino — depois do RandomUnderSampler	350	350	700	50,0%	1,00
Teste (nunca balanceado)	243	150	393	38,2%	1,62

Tabela 2 — Distribuição das classes antes e depois de cada técnica (as contagens são idênticas com KNN Imputer).

As duas técnicas chegam ao mesmo equilíbrio (50% e 50%) por caminhos opostos. O SMOTE-NC aumenta o treino para 1.132 exemplos e preserva toda a informação original. O RandomUnderSampler reduz o treino para 700 e perde 38% dos exemplos de não sobreviventes. O efeito de cada técnica sobre precisão e recall é discutido no item 4.e.

2. Árvore de Decisão e 3. Random Forest — otimização de hiperparâmetros

As otimizações dos itens 2.b e 3.b seguem o mesmo protocolo, para que a comparação entre otimizadores seja justa:

- **Otimizadores:** Random Search (RandomizedSearchCV) e Otimização Bayesiana com Optuna (amostrador TPE, cujas 10 primeiras tentativas são aleatórias).
- **Mesmo orçamento e mesma validação:** 50 configurações por busca, StratifiedKfold com os mesmos 5 folds para os dois otimizadores e os mesmos 4 processos paralelos nos dois casos.
- **Métrica otimizada:** F1-macro, a média do F1 das duas classes, que não favorece a classe majoritária como a acurácia.
- **Espaço da Árvore de Decisão:** criterion em {gini, entropy}, max_depth de 2 a 15, min_samples_split de 2 a 50 e min_samples_leaf de 1 a 30.
- **Espaço da Random Forest:** n_estimators de 50 a 300, max_depth de 2 a 20, min_samples_split de 2 a 30, min_samples_leaf de 1 a 15 e max_features em {sqrt, log2, None}.

Cada busca foi repetida nas 6 combinações de imputação e balanceamento, num total de 24 buscas. A Tabela 3 consolida os melhores hiperparâmetros e o tempo de cada uma.

Mod.	Imputação	Balanc.	Otimiz.	criterion	depth	split	leaf	n_est.	max_feat.	CV F1-macro	Tempo (s)
AD	KNN	Sem bal.	Random	entropy	6	26	1	—	—	0,7888	0,6
AD	KNN	Sem bal.	Optuna	entropy	7	30	2	—	—	0,7906	1,6
AD	KNN	SMOTE-NC	Random	gini	5	8	17	—	—	0,7857	3,2
AD	KNN	SMOTE-NC	Optuna	entropy	6	20	3	—	—	0,7830	4,9
AD	KNN	RUS	Random	entropy	7	14	1	—	—	0,7804	1,0
AD	KNN	RUS	Optuna	gini	6	15	3	—	—	0,7870	1,9
AD	MissForest	Sem bal.	Random	entropy	6	26	1	—	—	0,7826	0,7
AD	MissForest	Sem bal.	Optuna	gini	5	26	2	—	—	0,7863	1,4
AD	MissForest	SMOTE-NC	Random	gini	5	8	17	—	—	0,7792	2,1
AD	MissForest	SMOTE-NC	Optuna	gini	4	9	11	—	—	0,7805	3,3
AD	MissForest	RUS	Random	gini	3	13	3	—	—	0,7785	0,5
AD	MissForest	RUS	Optuna	gini	4	26	8	—	—	0,7795	1,4
RF	KNN	Sem bal.	Random	—	10	2	5	269	None	0,8038	9,7
RF	KNN	Sem bal.	Optuna	—	9	18	4	109	None	0,8048	12,6
RF	KNN	SMOTE-NC	Random	—	10	16	2	103	log2	0,7981	11,7
RF	KNN	SMOTE-NC	Optuna	—	12	25	5	128	log2	0,8022	14,7
RF	KNN	RUS	Random	—	10	2	5	269	None	0,7977	10,1
RF	KNN	RUS	Optuna	—	13	11	6	214	None	0,7986	12,9
RF	MissForest	Sem bal.	Random	—	10	16	2	103	log2	0,7960	9,8
RF	MissForest	Sem bal.	Optuna	—	14	19	2	58	None	0,7965	13,0
RF	MissForest	SMOTE-NC	Random	—	6	11	7	106	sqrt	0,7958	12,6
RF	MissForest	SMOTE-NC	Optuna	—	10	15	9	215	log2	0,7994	18,3
RF	MissForest	RUS	Random	—	10	2	5	269	None	0,7912	8,9
RF	MissForest	RUS	Optuna	—	16	18	1	100	None	0,7951	11,7

Tabela 3 — Hiperparâmetros encontrados pelos dois otimizadores para os dois modelos (itens 2.c e 3.c). depth = max_depth, split = min_samples_split, leaf = min_samples_leaf, n_est. = n_estimators, max_feat. = max_features; RUS = RandomUnderSampler; CV F1-macro = melhor média na validação cruzada de 5 folds; o tempo inclui o re-treino do melhor modelo.

Árvore de Decisão (2.c). As melhores árvores ficaram entre profundidade 3 e 7, com gini em 7 das 12 buscas e entropy em 5, e o F1-macro de validação variou pouco, de 0,779 a 0,791. O Random Search levou em média 1,4 s por busca e o Optuna, 2,4 s.

Random Forest (3.c). As florestas preferiram árvores mais profundas (max_depth de 6 a 16), já que a média de várias árvores compensa a variância de cada uma, e escolheram max_features = None em 7 das 12 buscas. O número de árvores variou muito, de 58 a 269, sem mudar a validação (0,791 a 0,805), o que indica que esse hiperparâmetro pesa pouco nesta base. Tempo médio por busca: 10,5 s no Random Search e 13,9 s no Optuna.

Algumas configurações do Random Search se repetem entre combinações, como n_estimators = 269, max_depth = 10, min_samples_leaf = 5 e max_features = None em três delas. Isso ocorre porque a mesma semente sorteia os mesmos 50 candidatos em todas as buscas, e só muda qual deles vence conforme os dados de cada combinação.

2.d) Regras da Árvore de Decisão otimizada

As regras vêm da árvore com maior F1-macro na validação cruzada entre as 6 configurações com MissForest: **sem balanceamento + Optuna**, com criterion = gini, max_depth = 5, min_samples_split = 26 e min_samples_leaf = 2. A escolha pela validação cruzada, e não pelo teste, evita ajustar a decisão ao conjunto de teste. A árvore tem 21 folhas e, portanto, 21 regras. Na Tabela 4, cada folha foi convertida em uma regra SE-ENTÃO: limites repetidos sobre o mesmo atributo foram fundidos e os atributos binários aparecem como categoria. A qualidade de cada regra é medida pela cobertura (fração dos passageiros que satisfazem o antecedente) e pela confiança (fração desses em que a classe prevista está correta), no treino

original e no teste. Importância dos atributos: sexo 0,59; pclass 0,13; fare 0,09; age 0,09; tem_cabine 0,06; sibsp 0,04.




Figura 2 — Árvore de Decisão otimizada (plot_tree).

	Regra (antecedente)	Classe	Cobertura treino	Confiança treino	Cobertura teste	Confiança teste
R1	mulher E classe ≤ 2 E tarifa > 31.7 E família ≤ 3	SOBREVIVEU	9,5%	100,0%	9,4%	97,3%
R2	mulher E classe ≥ 3 E 7.7 < tarifa ≤ 23.4 E idade ≤ 27.7	SOBREVIVEU	8,7%	61,3%	9,7%	55,3%
R3	homem E com cabine E idade > 17.8 E 26.1 < tarifa ≤ 31.7	SOBREVIVEU	2,7%	64,0%	2,5%	30,0%
R4	homem E sem cabine E idade ≤ 12.5 E sibsp ≤ 2	SOBREVIVEU	2,4%	68,2%	1,8%	85,7%
R5	mulher E classe ≤ 2 E tarifa ≤ 26.1 E sem cabine E título = Miss	SOBREVIVEU	2,3%	85,7%	2,8%	100,0%
R6	mulher E classe ≤ 2 E tarifa ≤ 26.1 E sem cabine E título ≠ Miss	SOBREVIVEU	2,2%	65,0%	3,6%	92,9%
R7	mulher E classe ≥ 3 E tarifa ≤ 7.7	SOBREVIVEU	2,0%	88,9%	2,0%	50,0%
R8	mulher E classe ≤ 2 E 26.1 < tarifa ≤ 31.7	SOBREVIVEU	1,6%	93,3%	2,8%	90,9%
R9	mulher E classe ≤ 2 E tarifa > 31.7 E família ≥ 4	SOBREVIVEU	1,6%	93,3%	1,5%	83,3%
R10	mulher E classe ≤ 2 E tarifa ≤ 26.1 E com cabine	SOBREVIVEU	1,2%	100,0%	0,5%	50,0%
R11	homem E com cabine E idade ≤ 17.8	SOBREVIVEU	0,8%	100,0%	0,8%	100,0%
R12	homem E sem cabine E idade > 12.5 E classe ≥ 2 E tarifa ≤ 51.7	NÃO SOBREVIVEU	44,2%	89,6%	42,7%	87,5%
R13	homem E com cabine E idade > 38.5 E tarifa > 31.7	NÃO SOBREVIVEU	4,0%	86,5%	3,3%	53,8%
R14	mulher E classe ≥ 3 E 7.7 < tarifa ≤ 23.4 E idade > 27.7	NÃO SOBREVIVEU	3,3%	66,7%	2,3%	66,7%
R15	homem E com cabine E 17.8 < idade ≤ 38.5 E tarifa > 31.7	NÃO SOBREVIVEU	3,1%	57,1%	1,8%	71,4%
R16	homem E sem cabine E 12.5 < idade ≤ 50.5 E classe ≤ 1	NÃO SOBREVIVEU	2,9%	66,7%	2,3%	88,9%
R17	mulher E classe ≥ 3 E tarifa > 23.4	NÃO SOBREVIVEU	2,2%	85,0%	3,3%	100,0%
R18	homem E sem cabine E idade ≤ 12.5 E sibsp ≥ 3	NÃO SOBREVIVEU	1,5%	100,0%	1,8%	85,7%
R19	homem E sem cabine E idade > 12.5 E classe ≥ 2 E tarifa > 51.7	NÃO SOBREVIVEU	1,5%	71,4%	2,0%	75,0%
R20	homem E com cabine E idade > 17.8 E tarifa ≤ 26.1	NÃO SOBREVIVEU	1,5%	64,3%	2,5%	90,0%
R21	homem E sem cabine E idade > 50.5 E classe ≤ 1	NÃO SOBREVIVEU	0,7%	100,0%	0,5%	100,0%

Tabela 4 — Regras extraídas (uma por folha), com cobertura e confiança no treino original e no teste.

Padrão de sobrevivência e mortalidade encontrado:

- **O sexo continua sendo o fator dominante**, com 59% da importância e posição de raiz na árvore. A maior regra, R12, cobre 43% dos passageiros do teste: *homem com mais de 12,5 anos, sem cabine registrada, de 2ª ou 3ª classe morreu em 87,5% dos casos.*

- **Mulheres de 1ª e 2ª classe sobreviveram** em quase todas as situações: R1, R5, R6, R8 e R9 têm confiança de 83% a 100% no teste. Só R1 cobre 9,4% do teste, com 97,3% de acerto.
- **Na 3ª classe, a tarifa separa as mulheres.** Com tarifa acima de 23,4 (bilhetes coletivos de famílias numerosas), elas morreram em 100% dos casos do teste (R17), o mesmo padrão da regra de famílias grandes da Lista 2. Com tarifa intermediária, as de até 27,7 anos sobreviveram em apenas 55% dos casos (R2), praticamente um sorteio.
- **"Mulheres e crianças primeiro" valeu para meninos de famílias pequenas.** Meninos de até 12,5 anos sem cabine sobreviveram em 86% dos casos quando tinham no máximo 2 irmãos a bordo (R4) e morreram em 86% quando tinham 3 ou mais (R18). Entre os homens com cabine, os menores de 17,8 anos sobreviveram (R11).
- **Regras frágeis:** R3 (homem com cabine, tarifa entre 26,1 e 31,7, sobreviveu) tem 64% de confiança no treino e só 30% no teste, e R13 cai de 86,5% para 53,8%. São folhas pequenas que capturaram ruído do treino e seriam as primeiras a desaparecer com uma poda mais agressiva.

Em resumo, o padrão da Lista 2 se confirma com mais detalhe: sobreviveram as mulheres das classes altas e as crianças de famílias pequenas; morreram os homens adultos, principalmente de 2ª e 3ª classe, e as famílias numerosas da 3ª classe.

4. Avaliação e comparação dos resultados

4.a) Métricas de desempenho

A Tabela 5 reúne os 24 modelos, já com os hiperparâmetros otimizados, avaliados no conjunto de teste. Precisão, recall e F1 referem-se à classe **sobreviveu (1)**, a minoritária; o F1-macro é a média do F1 das duas classes. Com 393 passageiros no teste, o erro padrão da acurácia fica em torno de ± 2 pontos percentuais, e diferenças menores que isso entre dois modelos isolados não são conclusivas. Por isso as comparações a seguir usam médias sobre várias combinações e a validação cruzada, além do teste.




Figura 3 — F1-macro no teste por combinação, AD × RF.

Mod.	Imputação	Balanc.	Otimiz.	CV F1-macro	Acurácia treino	Acurácia teste	Precisão (1)	Recall (1)	F1 (1)	F1-macro
AD	KNN	Sem bal.	Random	0,789	0,844	0,786	0,717	0,727	0,722	0,774
AD	KNN	Sem bal.	Optuna	0,791	0,837	0,791	0,758	0,667	0,709	0,773
AD	KNN	SMOTE-NC	Random	0,786	0,830	0,799	0,729	0,753	0,741	0,788
AD	KNN	SMOTE-NC	Optuna	0,783	0,838	0,804	0,732	0,767	0,749	0,794
AD	KNN	RUS	Random	0,780	0,844	0,779	0,693	0,753	0,722	0,769
AD	KNN	RUS	Optuna	0,787	0,833	0,786	0,701	0,767	0,732	0,777
AD	MissForest	Sem bal.	Random	0,783	0,841	0,807	0,753	0,733	0,743	0,794
AD	MissForest	Sem bal.	Optuna	0,786	0,835	0,819	0,769	0,753	0,761	0,808
AD	MissForest	SMOTE-NC	Random	0,779	0,829	0,809	0,752	0,747	0,749	0,798
AD	MissForest	SMOTE-NC	Optuna	0,781	0,818	0,802	0,722	0,780	0,750	0,793
AD	MissForest	RUS	Random	0,779	0,796	0,791	0,693	0,813	0,748	0,785
AD	MissForest	RUS	Optuna	0,779	0,823	0,802	0,740	0,740	0,740	0,790
RF	KNN	Sem bal.	Random	0,804	0,874	0,819	0,769	0,753	0,761	0,808
RF	KNN	Sem bal.	Optuna	0,805	0,862	0,822	0,782	0,740	0,760	0,809
RF	KNN	SMOTE-NC	Random	0,798	0,848	0,804	0,735	0,760	0,748	0,794
RF	KNN	SMOTE-NC	Optuna	0,802	0,833	0,807	0,734	0,773	0,753	0,797
RF	KNN	RUS	Random	0,798	0,856	0,799	0,718	0,780	0,748	0,790
RF	KNN	RUS	Optuna	0,799	0,850	0,794	0,709	0,780	0,743	0,785
RF	MissForest	Sem bal.	Random	0,796	0,852	0,830	0,790	0,753	0,771	0,818
RF	MissForest	Sem bal.	Optuna	0,796	0,868	0,819	0,776	0,740	0,758	0,807
RF	MissForest	SMOTE-NC	Random	0,796	0,829	0,814	0,745	0,780	0,762	0,805
RF	MissForest	SMOTE-NC	Optuna	0,799	0,828	0,807	0,731	0,780	0,755	0,798
RF	MissForest	RUS	Random	0,791	0,853	0,807	0,731	0,780	0,755	0,798
RF	MissForest	RUS	Optuna	0,795	0,855	0,799	0,713	0,793	0,751	0,791

Tabela 5 — Métricas no conjunto de teste (393 passageiros) para cada combinação. Precisão, recall e F1 da classe sobreviveu (1), a minoritária.

4.b) Árvore de Decisão × Random Forest

Médias sobre as 12 combinações de cada modelo:

Modelo	Acurácia treino	CV F1-macro	Acurácia teste	F1 (1) teste	F1-macro teste	Gap treino – teste
Random Forest	0,851	0,798	0,810	0,755	0,800	0,041
Árvore de Decisão	0,831	0,784	0,798	0,739	0,787	0,033

Tabela 6 — Médias por modelo (12 combinações de imputação, balanceamento e otimizador).

A Random Forest generaliza melhor. Seu F1-macro de validação cruzada é maior que o da Árvore de Decisão nas 12 combinações, e o F1-macro de teste é maior em 11 das 12. A única exceção (MissForest sem balanceamento, com Optuna) é um empate: 0,807 contra 0,808. A RF também é mais estável diante das escolhas de pré-processamento: a acurácia de teste varia de 0,794 a 0,830, contra 0,779 a 0,819 da árvore, cujo recall vai de 0,667 a 0,813.

O gap treino – teste um pouco maior da RF (4,1 contra 3,3 p.p.) não indica overfitting pior: ela ajusta melhor o treino e mesmo assim acerta mais fora dele, que é o que define a generalização. A Figura 4 compara os modelos escolhidos pela validação cruzada. A árvore sem balanceamento deixa passar mais sobreviventes (37 falsos negativos); a RF treinada com SMOTE-NC recupera 4 sobreviventes a mais ao custo de 9 falsos positivos a mais. Nesse par isolado a árvore teve F1-macro de teste um pouco maior (0,808 contra 0,798), uma diferença dentro do erro de ± 2 p.p. que mostra por que decidir com base em um único modelo no teste seria arriscado.




Figura 4 — Matrizes de confusão (teste) da melhor AD e da melhor RF.

4.c) Random Search × Otimização Bayesiana (Optuna)

Médias por modelo e otimizador (24 buscas com 50 avaliações cada):

Modelo	Otimizador	Tempo médio por busca (s)	CV F1-macro médio	F1-macro teste médio	Buscas com o maior CV
Árvore de Decisão	Random Search	1,4	0,783	0,785	1 de 6
Árvore de Decisão	Bayesiana (Optuna)	2,4	0,784	0,789	5 de 6
Random Forest	Random Search	10,5	0,797	0,802	0 de 6
Random Forest	Bayesiana (Optuna)	13,9	0,799	0,798	6 de 6

Tabela 7 — Comparação dos otimizadores de hiperparâmetros.

Hiperparâmetros encontrados. Na mesma combinação, os valores escolhidos pelos dois otimizadores mudam bastante. Na RF com MissForest e sem balanceamento, o Optuna escolheu 58 árvores com `max_depth = 14` e `max_features = None`, e o Random Search escolheu 103 árvores com `max_depth = 10` e `max_features = log2`. Na árvore, o `criterion` trocou entre `gini` e `entropy` em 3 das 6 combinações. Ainda assim a qualidade é praticamente a mesma. O Optuna teve CV maior em 11 das 12 buscas, mas com ganho de no máximo 0,007 (0,002 em média). No teste, o F1-macro médio empatou (0,7935 contra 0,7934), com o Optuna à frente em só 6 das 12 combinações. **A diferença nos hiperparâmetros é grande, mas a diferença na qualidade não é significativa.** A superfície de desempenho é um platô largo, em que configurações muito diferentes chegam ao mesmo F1.

Eficiência. Na Figura 5, o Optuna começa atrás na árvore, porque suas 10 primeiras tentativas são aleatórias, passa o Random Search por volta da 17ª iteração e termina com 99,9% do melhor valor, contra 99,7%. Na RF ele fica à frente desde as primeiras iterações. Em tempo, porém, o Optuna custou em média 2,1 vezes o tempo do Random Search na árvore e 1,3 vezes na RF. O RandomizedSearchCV envia os 250 treinos (50 configurações × 5 folds) de uma vez para os processos paralelos. O Optuna precisa concluir uma tentativa para escolher a próxima, o que deixa núcleos ociosos e pesa mais quando cada treino dura milissegundos, como na árvore. **Neste problema, o Random Search teve a melhor relação entre tempo e qualidade:** chegou, em média, a 99,7% do melhor valor gastando menos tempo. A vantagem do Optuna aparece quando cada avaliação é cara ou o espaço de busca é grande, e aqui, com 4 ou 5 hiperparâmetros e uma base pequena, nenhuma das duas condições vale.




Figura 5 — Convergência das buscas: melhor CV F1-macro até cada iteração.

4.d) KNN Imputer × MissForest

Médias por modelo e método de imputação:

Modelo	Imputação	CV F1-macro	Acurácia teste	Precisão (1)	Recall (1)	F1-macro teste
Árvore de Decisão	KNN Imputer	0,786	0,791	0,722	0,739	0,779
Árvore de Decisão	MissForest	0,781	0,805	0,738	0,761	0,795
Random Forest	KNN Imputer	0,801	0,807	0,741	0,764	0,797
Random Forest	MissForest	0,796	0,813	0,748	0,771	0,803

Tabela 8 — Desempenho médio por método de imputação (6 modelos cada).

Desempenho final: não houve diferença relevante. Os dois critérios apontam em sentidos opostos. No teste, o MissForest ficou à frente (+1,6 p.p. de F1-macro na árvore e +0,6 p.p. na RF); na validação cruzada, calculada em 5 folds sobre os 916 passageiros de treino, o KNN ficou à frente (+0,5 p.p. nos dois modelos). Diferenças desse tamanho e com sinais trocados estão dentro do ruído de amostragem. Isso é coerente com o problema: *age* é só o 4º atributo em importância (0,09), os ausentes são 20% de um único atributo e as idades imputadas pelos dois métodos são parecidas em média (28,9 e 29,1 anos).

Distribuição original: o MissForest a preservou melhor (Tabela 1). Teve KS de 0,036 ($p = 0,66$) contra 0,064 ($p = 0,067$), assimetria igual à original e menor erro ao recuperar idades escondidas (MAE de 8,55 contra 8,68). O KNN só leva vantagem na distância de Wasserstein (0,84 contra 0,91) e no tempo de execução.

4.e) SMOTE-NC × RandomUnderSampler

Médias por modelo e técnica de balanceamento (classe 1 = sobreviveu, minoritária):

Modelo	Balanceamento	Precisão (1)	Recall (1)	Precisão – Recall	F1 (1)	Recall (0)	F1-macro
Árvore de Decisão	Sem balanceamento	0,749	0,720	0,029	0,734	0,851	0,787
Árvore de Decisão	SMOTE-NC	0,734	0,762	0,028	0,747	0,829	0,793
Árvore de Decisão	RandomUnderSampler	0,707	0,768	0,061	0,736	0,802	0,780
Random Forest	Sem balanceamento	0,779	0,747	0,033	0,763	0,869	0,810
Random Forest	SMOTE-NC	0,737	0,773	0,037	0,754	0,829	0,798
Random Forest	RandomUnderSampler	0,718	0,783	0,066	0,749	0,810	0,791

Tabela 9 — Precisão e recall por técnica de balanceamento (4 modelos cada).

O SMOTE-NC produziu o melhor equilíbrio entre precisão e recall da classe minoritária. Nos dois modelos ele manteve precisão e recall próximos (diferença de 2,8 p.p. na árvore e 3,7 p.p. na RF) e obteve F1 da classe sobreviveu maior que o do RandomUnderSampler. O RandomUnderSampler dá o maior recall (0,768 e 0,783), mas com a menor precisão (0,707 e 0,718) e a maior distância entre as duas (6,1 e 6,6 p.p.). Ao descartar 38% dos não sobreviventes, o modelo vê menos exemplos de quem morreu e passa a prever "sobreviveu" com mais facilidade, gerando mais falsos positivos: o recall da classe 0 cai para 0,80 e

0,81. Na Figura 6, os triângulos (RandomUnderSampler) ficam abaixo e à direita da diagonal, e os quadrados (SMOTE-NC) ficam mais perto dela.

Em relação a não balancear, o efeito depende do modelo. Na árvore, o SMOTE-NC aumentou o recall dos sobreviventes em 4,2 p.p. e o F1 em 1,3 p.p. Na RF, o melhor F1 e o melhor F1-macro vieram *sem* balanceamento: com um desbalanceamento de apenas 1,62 : 1, a floresta já separa bem as classes, e balancear apenas desloca o ponto de operação, trocando precisão por recall. Para não deixar de identificar sobreviventes, o SMOTE-NC é a melhor escolha; para acertar o máximo no geral, não balancear foi suficiente na RF.




Figura 6 — Precisão × recall da classe sobreviveu para os 24 modelos.

4.f) Interpretabilidade: Árvore de Decisão × Random Forest

Não da mesma forma. A Árvore de Decisão escolhida tem 21 regras com profundidade de até 5, e cada previsão segue um único caminho legível (Tabela 4). A Random Forest escolhida (MissForest + SMOTE-NC + Optuna: 215 árvores, max_depth = 10, max_features = log2) tem árvores com profundidade média de 9,3 e cerca de 36 folhas cada, ou seja, **7.798 regras**, e a previsão é o voto de todas elas. Não existe "a regra" da floresta.

As árvores da floresta também não repetem a árvore única. *sexo*, raiz da Árvore de Decisão, é raiz de só 41 das 215 árvores (19%); as demais começam por *título_Mr* (43), *título_Mrs* (30), *título_Miss* (26), *tem_cabine* (24), *fare* (20), *pclass* (16) e outros. Com max_features = log2, cada divisão sorteia só 4 dos 16 atributos, e quando *sexo* não é sorteado a árvore usa um substituto, como o título. Na Figura 7, a importância concentrada em *sexo* na árvore (0,59) aparece dividida na floresta entre *título_Mr* (0,21), *sexo* (0,20) e os outros títulos. O padrão global continua o mesmo (*sexo* e título, tarifa, idade, classe), mas só pode ser lido de forma agregada, pela importância dos atributos, e não como regras SE–ENTÃO.

Por que a RF prevê melhor? Uma única árvore tem baixo viés e alta variância: pequenas mudanças no treino alteram os cortes, como na Lista 2, em que a raiz mudou conforme a amostra de treino. A RF treina cada árvore em uma amostra bootstrap e sorteia atributos a cada divisão, o que gera árvores diferentes e pouco correlacionadas. A média dos votos cancela boa parte dos erros individuais e reduz a variância sem aumentar o viés. Foi isso que produziu o CV maior nas 12 combinações e os resultados mais estáveis entre pré-processamentos.

Por que é menos interpretável? Pelo mesmo motivo: a decisão fica distribuída entre centenas de árvores diferentes. A importância dos atributos mostra *quais* atributos pesam, mas não *como* pesam (limiares, interações, direção do efeito), e reunir 7.798 regras em uma explicação legível não é viável. Explicar uma RF exige aproximações, como importância por permutação, SHAP ou uma árvore substituta treinada para imitar a floresta, e essas aproximações já não são o modelo em si. É o compromisso clássico: a Árvore de

Decisão entrega regras auditáveis com F1-macro cerca de 1,3 p.p. menor, e a Random Forest ganha desempenho e estabilidade às custas da transparência.



Figura 7 — Importância dos atributos na AD e na RF.

Conclusão

A imputação e o balanceamento importaram menos que a escolha do modelo. Entre os imputadores, o MissForest preservou melhor a distribuição de *age* (KS de 0,036 contra 0,064, assimetria mantida e menor erro nas idades escondidas), mas o desempenho final dos modelos não mudou de forma relevante: o MissForest ficou à frente no teste e o KNN na validação cruzada, sempre por menos de 2 p.p. (4.d). Entre as técnicas de balanceamento, o SMOTE-NC deu o melhor equilíbrio entre precisão e recall dos sobreviventes, enquanto o RandomUnderSampler ganhou recall à custa de precisão ao descartar 38% dos não sobreviventes. Com um desbalanceamento moderado (1,62 : 1), porém, não balancear continuou competitivo, sobretudo na Random Forest (4.e). O SMOTE clássico foi substituído pelo SMOTE-NC porque gerava categorias impossíveis, como *sexo* = 0,37, que produziam regras falsas.

Entre os otimizadores, Random Search e Otimização Bayesiana chegaram a hiperparâmetros bem diferentes, mas de qualidade equivalente. O Optuna venceu na validação em 11 das 12 buscas com ganho médio de apenas 0,002 e empatou no teste, enquanto o Random Search foi mais rápido. Neste problema, com espaço de busca pequeno e modelos baratos, o Random Search teve a melhor relação entre tempo e qualidade (4.c). A Random Forest generalizou melhor que a Árvore de Decisão: F1-macro de validação maior nas 12 combinações, maior no teste em 11 delas e menor variação entre pré-processamentos (4.b), graças à redução de variância obtida com bootstrap e sorteio de atributos. O preço é a interpretabilidade: as 21 regras da árvore dão lugar a 7.798 regras espalhadas por 215 árvores com raízes diferentes, e o padrão só pode ser lido de forma agregada (4.f).

O padrão de sobrevivência se manteve em todas as análises e confirma a Lista 2. O *sexo* é o fator decisivo: tem 59% da importância na árvore e, na floresta, *sexo* e títulos somam 0,57, com Mr, Mrs e Miss atuando como substitutos do *sexo*. Sobreviveram as mulheres de 1ª e 2ª classe e os meninos de famílias pequenas; morreram os homens adultos de 2ª e 3ª classe e as famílias numerosas da 3ª classe.

Achado principal: sobreviveram as mulheres das classes altas e as crianças de famílias pequenas; morreram os homens adultos de 2ª e 3ª classe e as famílias numerosas da 3ª classe. A Random Forest prevê esse padrão melhor, mas só a Árvore de Decisão o explica em regras.