Lista 5

Link para o código desenvolvido

https://colab.research.google.com/drive/17ylSyhVSVQDowY-jNziS1hzaiiaya1fP?usp=sharing

O ponto de partida foi o notebook `Apriori.ipynb` da disciplina (Página Inicial / Códigos em Python): biblioteca `apyori`, conversão da base em lista de transações, chamada `apriori(transacoes, min_support, min_confidence)` e montagem do DataFrame `RegrasFinais` com antecedente, consequente, suporte, confiança e lift. As adaptações foram o pré-processamento da base Titanic, a criação dos itens de ausência, a busca do suporte e da confiança e os filtros de regras triviais e redundantes, descritos a seguir. A base é a mesma das Listas 2 e 3 (*titanic completo.csv*, 1.309 passageiros e 14 atributos), e a execução completa do notebook leva cerca de 15 segundos.

Questão 07 — Regras de associação com o Apriori

1. Pré-processamento da base

1.a) Valores ausentes e remoção de atributos

Atributo	Ausentes	Tratamento
age	263 (20,1%)	Mediana da idade por título extraído do nome (Mr 29, Mrs 35, Miss 22, Master 4, Raro 47,5), mesma estratégia da Lista 2.
fare	1	Mediana da tarifa da mesma classe.
embarked	2	Moda (S, Southampton).
name, ticket, cabin, home.dest	—	Removidos: identificadores ou texto livre (quase um valor por passageiro, nunca atingiriam o suporte mínimo). *name* é usado antes para extrair o título.
boat, body	—	Removidos por vazamento: *boat* só existe para quem foi resgatado e *body* só para quem morreu; gerariam regras óbvias como {boat=13} → {Sobreviveu=Sim}.
sibsp, parch	0	Somados em *tam_familia* (parentes a bordo).

Tabela 1 — Tratamento de cada atributo da base original.

A mediana por título respeita o perfil do passageiro: o título carrega sexo e faixa etária (Master = menino, Miss = em geral moça solteira). Com a mediana global (28 anos), todo menino `Master` sem idade seria tratado como adulto e sairia da faixa de crianças.

1.b) Discretização dos atributos numéricos

Critérios: faixas com **significado** (interpretáveis em uma regra) e com **passageiros suficientes** para atingir o suporte mínimo (uma faixa com 2% da base nunca aparece em regras com suporte de 5%).

- **Idade: 0–12, 13–22, 23–40, 41+.** É a sugestão do enunciado com o primeiro corte em 12 em vez de 17, para isolar as crianças (todo `Master` imputado cai aqui), grupo da política "mulheres e crianças primeiro". 13–17 sozinho teria só 60 passageiros (4,6%), então foi unido a 18–22. 23–40 é a faixa modal. 41+ junta meia-idade e idosos, porque 61+ teria só 33 passageiros (2,5%).
- **Tarifa: Baixa (≤ 8,66), Média (8,66–26], Alta (> 26)** — tercis. A distribuição é muito assimétrica (mediana 14,45, máximo 512,33), então faixas de largura igual deixariam quase todos na primeira. Com tercis, cada faixa tem cerca de 1/3 da base.
- **Família: Sozinho (0), Pequena (1–3), Grande (4+)** — mesmo agrupamento da Lista 2, com taxas de sobrevivência bem diferentes (30%, 56% e 18%).
- `pclass`, `sex`, `embarked` e `survived` já são categóricos e só foram renomeados (Classe, Sexo, Embarque, Sobreviveu).

Atributo	Valor	Passageiros	% da base	% sobreviveu
Classe	1ª	323	24,7%	61,9%
Classe	2ª	277	21,2%	43,0%
Classe	3ª	709	54,2%	25,5%
Sexo	Feminino	466	35,6%	72,7%
Sexo	Masculino	843	64,4%	19,1%
Idade	0-12	102	7,8%	55,9%
Idade	13-22	290	22,2%	41,7%
Idade	23-40	689	52,6%	33,7%
Idade	41+	228	17,4%	39,5%
Tarifa	Alta	426	32,5%	56,1%
Tarifa	Baixa	455	34,8%	22,0%
Tarifa	Média	428	32,7%	37,6%
Família	Grande	82	6,3%	18,3%
Família	Pequena	437	33,4%	56,3%
Família	Sozinho	790	60,4%	30,3%
Embarque	Cherbourg	270	20,6%	55,6%
Embarque	Queenstown	123	9,4%	35,8%
Embarque	Southampton	916	70,0%	33,4%

Tabela 2 — Itens de presença após a discretização: frequência e taxa de sobrevivência (geral: 38,2%).

1.c) Formato transacional e binário (one-hot)

Cada `atributo=valor` vira um item (`Classe=1ª`, `Idade=13-22`, `Sobreviveu=Não`). O `apyori` recebe a lista de transações, como no notebook da disciplina, e o notebook mostra também a matriz binária one-hot equivalente (1.309 × 20 com os itens de presença, 1.309 × 36 com os de ausência), em que cada coluna é um item. Exemplo da primeira transação, já com os itens de ausência da seção 2:

```
['Classe=1ª', 'Sexo=Feminino', 'Idade=23-40', 'Tarifa=Alta', 'Família=Sozinho',
 'Embarque=Southampton', 'Sobreviveu=Sim', 'NÃO Classe=2ª', 'NÃO Classe=3ª', 'NÃO Idade=0-12',
 'NÃO Idade=13-22', 'NÃO Idade=41+', 'NÃO Tarifa=Baixa', 'NÃO Tarifa=Média', 'NÃO Família=Grande',
 'NÃO Família=Pequena', 'NÃO Embarque=Cherbourg', 'NÃO Embarque=Queenstown']
```

2. Regras com presença e ausência de características

Para cada atributo com **três ou mais valores** (Classe, Idade, Tarifa, Família e Embarque), cada transação recebe, além do item presente, um item `NÃO atributo=valor` para **cada valor que o passageiro não tem**. Um passageiro da 3ª classe recebe `Classe=3ª`, `NÃO Classe=1ª` e `NÃO Classe=2ª`. Decisões de implementação:

- **Sexo e Sobreviveu não recebem itens de ausência.** São binários, então `NÃO Sexo=Masculino` é exatamente `Sexo=Feminino` e `NÃO Sobreviveu=Sim` é `Sobreviveu=Não`. Os itens de ausência só duplicariam itens existentes, e cada regra sairia em dois exemplares idênticos.
- Na lista de transações, os itens de ausência são o domínio do atributo menos o valor presente. Na matriz binária, a coluna `NÃO X=v` é `1 − (coluna X=v)`.
- Cada transação passa de 7 para 18 itens (7 de presença + 2 + 3 + 2 + 2 + 2 de ausência).
- Itens de ausência têm **suporte muito alto** (`NÃO Família=Grande` = 0,937, `NÃO Idade=0-12` = 0,922), o que multiplica o número de itemsets frequentes e de regras redundantes. Isso é tratado com os filtros da seção 3.

```
ATRIB_AUSENCIA = ['Classe', 'Idade', 'Tarifa', 'Família', 'Embarque']
DOMINIO = {a: sorted(disc[a].unique()) for a in disc.columns}

def transacao(linha):
    itens = [f'{a}={linha[a]}' for a in disc.columns]
    for a in ATRIB_AUSENCIA:
        itens += [f'NÃO {a}={v}' for v in DOMINIO[a] if v != linha[a]]
```

```
        return itens

transacoes = [transacao(linha) for _, linha in disc.iterrows()]
```

3. Geração das regras

3.a) Apriori e filtros

O Apriori é executado com a mesma chamada do notebook da disciplina, e as regras são convertidas no DataFrame `RegrasFinais` pelo mesmo laço. Rodar o Apriori "puro" sobre as transações com itens de ausência gera dezenas de milhares de regras, quase todas variações umas das outras. Por isso foram aplicados, nesta ordem:

- `max_length = 3` (parâmetro do `apyori`): regras com até 2 itens no antecedente e 1 no consequente, o mesmo formato do exemplo do enunciado. Com 3 itens no antecedente, o número de regras quadruplica.
- **Atributo repetido:** descarta regras em que o mesmo atributo aparece duas vezes, como `{Classe=3ª}` → `{NÃO Classe=1ª}` (confiança 1 por definição) ou `{NÃO Classe=1ª, NÃO Classe=2ª}` → … (que é só `Classe=3ª` escrito de outro jeito).
- **Consequente com um único item de presença:** o objetivo é descrever o perfil que leva a uma característica. Um consequente como `NÃO Idade=0-12` só diz "é de uma das outras três faixas" e quase sempre é trivial (92% da base não é criança).
- **Lift ≥ 1,2:** o antecedente precisa aumentar em pelo menos 20% a chance do consequente. Regras com lift perto de 1 são triviais, porque o consequente já é frequente sozinho.
- **Melhoria mínima ≥ 0,05** (*minimum improvement*, Bayardo et al., 2000): a confiança precisa superar em 5 pontos percentuais a de toda regra mais simples com o mesmo consequente (cada item do antecedente sozinho e a regra vazia, cuja confiança é o suporte do consequente). Sem isso, a lista fica cheia de cópias como `{Sexo=Feminino, NÃO Embarque=Queenstown}` → `{Sobreviveu=Sim}`, em que o item de ausência não acrescenta nada a `{Sexo=Feminino}` → `{Sobreviveu=Sim}`.

3.b) Ajuste do suporte mínimo e da confiança mínima

Foram testados 5 suportes × 5 confianças. Para cada suporte, o Apriori roda uma vez com confiança 0,5, e as confianças maiores são aplicadas por filtro, com resultado idêntico ao de rodar de novo. A Tabela 3 mostra quantas regras sobram após cada etapa.

Sup.	Conf.	Brutas	Sem atr. repetido	Cons. único	Lift ≥ 1,2	Finais	→ Sim	→ Não	C/ ausência
0,01	0,5	13.012	8.768	2360	1019	430	61	28	214
0,01	0,6	9.781	6.417	1511	709	323	50	28	155
0,01	0,7	7.326	4.623	804	526	215	18	28	92
0,01	0,8	4.980	2.907	331	314	137	12	17	50
0,01	0,9	3.165	1.599	121	121	53	5	4	16
0,03	0,5	12.542	8.398	2186	909	366	48	24	189
0,03	0,6	9.397	6.130	1396	625	272	40	24	135
0,03	0,7	7.000	4.391	725	465	178	14	24	77
0,03	0,8	4.720	2.735	285	272	109	9	13	37
0,03	0,9	2.964	1.480	96	96	33	3	2	7
0,05	0,5	11.706	7.774	1954	752	300	41	17	168
0,05	0,6	8.794	5.674	1250	512	219	35	17	119
0,05	**0,7**	**6.491**	**4.018**	**615**	**373**	**140**	**11**	**17**	**67**
0,05	0,8	4.341	2.478	208	199	77	7	6	30
0,05	0,9	2.701	1.331	76	76	22	3	0	6
0,10	0,5	9.945	6.545	1531	539	192	23	13	119
0,10	0,6	7.451	4.823	1011	379	140	18	13	83

Sup.	Conf.	Brutas	Sem atr. repetido	Cons. único	Lift ≥ 1,2	Finais	→ Sim	→ Não	C/ ausência
0,10	0,7	5.416	3.402	501	281	94	7	13	49
0,10	0,8	3.487	2.028	148	139	49	5	4	21
0,10	0,9	2.088	1.052	54	54	15	2	0	5
0,20	0,5	6.400	4.167	836	239	76	2	12	49
0,20	0,6	5.113	3.272	645	207	64	1	12	38
0,20	0,7	3.680	2.315	353	174	51	1	12	29
0,20	0,8	2.262	1.310	79	75	20	0	3	8
0,20	0,9	1.286	650	31	31	5	0	0	1

Tabela 3 — Número de regras por configuração após cada filtro (em negrito, a configuração escolhida). → Sim / → Não = regras finais com consequente Sobreviveu=Sim / Sobreviveu=Não; C/ ausência = regras finais com item de ausência no antecedente.

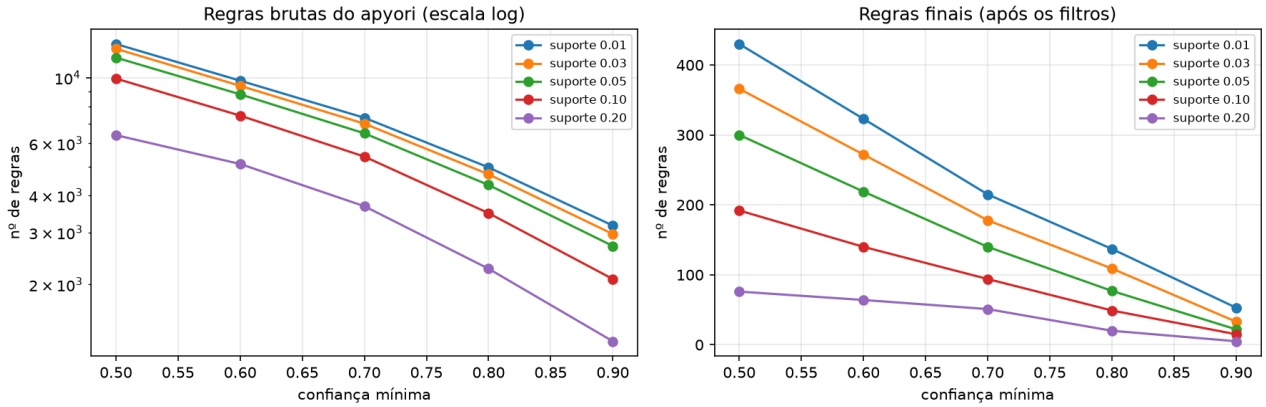


Figura 1 — Regras brutas (escala log) e regras finais em função do suporte e da confiança mínimos.

Escolha da configuração. A grade mostra o comportamento esperado: diminuir o suporte ou a confiança faz o número de regras crescer muito. As regras brutas vão de 1.286 (suporte 0,20 / confiança 0,9) a 13.012 (0,01 / 0,5), e o filtro de redundância, o de consequente único, o de lift e o de melhoria reduzem esse volume para 5 a 430 regras finais. Os extremos foram descartados pelos seguintes motivos:

- **Suporte 0,01 e 0,03:** geram 178 a 430 regras finais, muitas sobre grupos de 13 a 40 passageiros (1% a 3% da base), em que uma ou duas pessoas mudam a confiança em vários pontos. São padrões pouco confiáveis estatisticamente e difíceis de revisar à mão.
- **Suporte 0,20:** só sobram regras sobre grupos muito grandes, com no máximo 2 regras para `Sobreviveu=Sim`. Perde-se, por exemplo, `{Classe=1ª, Sexo=Feminino}` → `{Sobreviveu=Sim}`, que cobre 10,6% da base e é a regra de sobrevivência mais forte.
- **Confiança 0,5 e 0,6:** aceitam regras que acertam só metade das vezes. Para `Sobreviveu=Não`, cuja taxa geral é 61,8%, uma confiança de 0,6 está abaixo da própria taxa da base.
- **Confiança 0,9:** sobram no máximo 3 regras para `Sobreviveu=Sim` e nenhuma para `Sobreviveu=Não` com suporte ≥ 0,05, porque quase nenhum grupo de 5% da base morreu em mais de 90% dos casos.

Configuração escolhida: suporte mínimo 0,05 e confiança mínima 0,7. Cada regra cobre pelo menos 66 passageiros e acerta pelo menos 70% das vezes. O resultado são **140 regras** finais, com **11 para** `Sobreviveu=Sim`, **17 para** `Sobreviveu=Não` e **67 com itens de ausência** no antecedente: um volume que dá para ler inteiro e que contém os dois lados da sobrevivência. A configuração 0,05 / 0,8 seria a alternativa mais enxuta (77 regras), mas fica com só 6 regras de morte.

3.c) Suporte, confiança e lift de cada regra

As 140 regras da configuração escolhida estão no Anexo (Tabela 7), ordenadas por lift, com suporte, confiança, lift e melhoria. A numeração (nº) é usada nas tabelas seguintes. O notebook mostra a mesma tabela completa e a salva em `regras_finais.csv`.

4. Análise dos resultados

4.a) Regras mais relevantes

nº	Antecedente	Consequente	Suporte	Confiança	Lift	Melhoria
1	{Embarque=Cherbourg, Tarifa=Alta}	{Classe=1ª}	0,106	0,927	3,755	0,220
2	{Idade=41+, Tarifa=Alta}	{Classe=1ª}	0,092	0,903	3,659	0,196
3	{NÃO Embarque=Southampton, Tarifa=Alta}	{Classe=1ª}	0,108	0,893	3,619	0,187
4	{Família=Sozinho, Tarifa=Alta}	{Classe=1ª}	0,106	0,891	3,611	0,184
5	{Sobreviveu=Sim, Tarifa=Alta}	{Classe=1ª}	0,148	0,812	3,290	0,105
6	{NÃO Família=Grande, Tarifa=Alta}	{Classe=1ª}	0,222	0,808	3,274	0,101
7	{NÃO Idade=0-12, Tarifa=Alta}	{Classe=1ª}	0,226	0,779	3,157	0,072
8	{Idade=41+, Sobreviveu=Sim}	{Classe=1ª}	0,053	0,767	3,107	0,196
9	{Idade=23-40, Tarifa=Alta}	{Classe=1ª}	0,108	0,766	3,106	0,060
10	{Classe=1ª, NÃO Família=Sozinho}	{Tarifa=Alta}	0,124	0,994	3,054	0,062
11	{Classe=1ª, Família=Pequena}	{Tarifa=Alta}	0,115	0,993	3,053	0,062
12	{Classe=1ª, NÃO Embarque=Southampton}	{Tarifa=Alta}	0,108	0,986	3,030	0,054
13	{Classe=1ª, Embarque=Cherbourg}	{Tarifa=Alta}	0,106	0,986	3,029	0,054
14	{Idade=41+, NÃO Tarifa=Média}	{Classe=1ª}	0,093	0,726	2,943	0,156
15	{Classe=1ª}	{Tarifa=Alta}	0,230	0,932	2,863	0,606

Tabela 4 — As 15 regras de maior lift.

Regras mais relevantes. As regras de maior lift (3,0 a 3,8) relacionam **classe e tarifa**: `{Embarque=Cherbourg, Tarifa=Alta} → {Classe=1ª}` (confiança 0,93, lift 3,76), `{Classe=1ª, Família=Pequena} → {Tarifa=Alta}` (0,99), `{Classe=1ª} → {Tarifa=Alta}` (0,93). São verdadeiras, mas previsíveis: a tarifa é consequência da classe. O lift alto vem do fato de a 1ª classe ter só 24,7% da base. Mesmo assim, elas revelam dois detalhes:

- **Cherbourg concentra a 1ª classe**: 52% dos embarcados lá eram da 1ª classe (contra 25% na base), e quase todo passageiro de tarifa alta embarcado em Cherbourg era da 1ª classe.
- `{Família=Grande} → {Tarifa=Alta}` (0,82, lift 2,51) parece contradizer `{Família=Grande} → {Classe=3ª}` (0,84). A explicação é que, nesta base, `fare` é o valor do **bilhete**, compartilhado por todos que viajam nele: famílias grandes da 3ª classe pagavam um bilhete caro em valor total, mas barato por pessoa (mediana de 32,88 por bilhete e de cerca de 5,67 por pessoa).

Por consequente, as 140 regras se distribuem entre `Classe=3ª` (20), `Sexo=Masculino` (20), `Sobreviveu=Não` (17), `Tarifa=Alta` (16), `Família=Sozinho` (14), `Classe=1ª` (11), `Sobreviveu=Sim` (11), `Embarque=Southampton` (10) e outros. Logo depois das regras de classe/tarifa, aparecem as de **sexo e sobrevivência**, que estão entre as de maior lift fora desse grupo: `{Classe=1ª, Sexo=Feminino} → {Sobreviveu=Sim}` (lift 2,53) é a 22ª regra no ranking geral.

4.b) Regras cujo consequente é a sobrevivência

nº	Antecedente	Consequente	Suporte	Confiança	Lift	Melhoria
22	{Classe=1ª, Sexo=Feminino}	{Sobreviveu=Sim}	0,106	0,965	2,527	0,238
27	{NÃO Classe=3ª, Sexo=Feminino}	{Sobreviveu=Sim}	0,178	0,932	2,440	0,205
31	{Embarque=Cherbourg, Sexo=Feminino}	{Sobreviveu=Sim}	0,078	0,903	2,363	0,175
36	{Classe=2ª, Sexo=Feminino}	{Sobreviveu=Sim}	0,072	0,887	2,322	0,159
39	{Sexo=Feminino, Tarifa=Alta}	{Sobreviveu=Sim}	0,128	0,862	2,256	0,134
50	{NÃO Embarque=Southampton, Sexo=Feminino}	{Sobreviveu=Sim}	0,106	0,803	2,103	0,076
51	{Família=Pequena, Sexo=Feminino}	{Sobreviveu=Sim}	0,141	0,801	2,097	0,073
56	{Sexo=Feminino}	{Sobreviveu=Sim}	0,259	0,727	1,905	0,345
57	{Classe=1ª, NÃO Família=Sozinho}	{Sobreviveu=Sim}	0,090	0,724	1,895	0,105
58	{Classe=1ª, Família=Pequena}	{Sobreviveu=Sim}	0,084	0,724	1,895	0,104
59	{Família=Pequena, Tarifa=Alta}	{Sobreviveu=Sim}	0,109	0,704	1,844	0,142

Tabela 5a — As 11 regras com consequente Sobreviveu=Sim, por lift.

nº	Antecedente	Consequente	Suporte	Confiança	Lift	Melhoria
80	{Sexo=Masculino, Tarifa=Baixa}	{Sobreviveu=Não}	0,239	0,869	1,407	0,060
83	{Idade=13-22, Sexo=Masculino}	{Sobreviveu=Não}	0,093	0,859	1,390	0,050
86	{Idade=23-40, Tarifa=Baixa}	{Sobreviveu=Não}	0,177	0,850	1,375	0,070
88	{NÃO Idade=13-22, Tarifa=Baixa}	{Sobreviveu=Não}	0,200	0,845	1,368	0,065
98	{Família=Grande}	{Sobreviveu=Não}	0,051	0,817	1,322	0,199
102	{Sexo=Masculino}	{Sobreviveu=Não}	0,521	0,809	1,309	0,191
104	{Classe=3ª, Idade=23-40}	{Sobreviveu=Não}	0,231	0,799	1,294	0,055
109	{Idade=41+, NÃO Classe=1ª}	{Sobreviveu=Não}	0,059	0,786	1,271	0,090
112	{Tarifa=Baixa}	{Sobreviveu=Não}	0,271	0,780	1,262	0,162
117	{Idade=41+, NÃO Tarifa=Alta}	{Sobreviveu=Não}	0,056	0,777	1,257	0,072
122	{Idade=23-40, NÃO Tarifa=Alta}	{Sobreviveu=Não}	0,297	0,770	1,246	0,066
125	{NÃO Classe=1ª, NÃO Família=Pequena}	{Sobreviveu=Não}	0,410	0,766	1,240	0,057
132	{Família=Sozinho, NÃO Tarifa=Alta}	{Sobreviveu=Não}	0,367	0,757	1,225	0,053
135	{Idade=23-40, NÃO Classe=1ª}	{Sobreviveu=Não}	0,307	0,751	1,216	0,056
136	{Família=Sozinho, NÃO Classe=1ª}	{Sobreviveu=Não}	0,361	0,751	1,215	0,053
137	{NÃO Classe=1ª, NÃO Tarifa=Média}	{Sobreviveu=Não}	0,327	0,748	1,211	0,053
140	{Classe=3ª}	{Sobreviveu=Não}	0,403	0,745	1,205	0,127

Tabela 5b — As 17 regras com consequente Sobreviveu=Não, por lift.

Regras com consequente `Sobreviveu=Sim` **(11 regras).** Todas, menos três, têm `Sexo=Feminino` no antecedente. A regra simples `{Sexo=Feminino} → {Sobreviveu=Sim}` já tem confiança 0,727 (contra 38,2% na base), e as demais mostram **quais mulheres** sobreviveram mais: as da 1ª classe (0,965), as que não eram da 3ª classe (0,932), as embarcadas em Cherbourg (0,903), as da 2ª classe (0,887), as de tarifa alta (0,862) e as com família pequena (0,801). As três regras sem sexo no antecedente envolvem 1ª classe ou tarifa alta **junto com família pequena** (`{Classe=1ª, Família=Pequena}`, `{Classe=1ª, NÃO Família=Sozinho}`, `{Família=Pequena, Tarifa=Alta}`, confiança 0,70 a 0,72): ser rico e estar acompanhado de poucos familiares bastava para sobreviver na maioria dos casos, mesmo sem ser mulher. Nenhuma regra tem `Sexo=Masculino` ou `Classe=3ª` levando a `Sobreviveu=Sim`.

Uma ausência notável: **não há regra** `{Idade=0-12} → {Sobreviveu=Sim}`. As crianças sobreviveram 55,9% das vezes, acima da média, mas abaixo da confiança mínima de 0,7. A regra `{Idade=0-12} → {Classe=3ª}` (0,716) explica: 72% das crianças estavam na 3ª classe, onde só 40% delas sobreviveram, contra 100% das 24 crianças da 2ª classe. O "mulheres e crianças primeiro" aparece com força nas mulheres, mas, nas crianças, a classe pesou mais.

Regras com consequente `Sobreviveu=Não` **(17 regras).** O perfil é o oposto: **homem, 3ª classe ou tarifa baixa, adulto jovem e viajando sozinho**. As de maior confiança são `{Sexo=Masculino, Tarifa=Baixa}` (0,869), `{Idade=13-22, Sexo=Masculino}` (0,859), `{Idade=23-40, Tarifa=Baixa}` (0,850) e `{Família=Grande}` (0,817). As regras simples `{Sexo=Masculino}` (0,809),

`{Tarifa=Baixa}` (0,780) e `{Classe=3ª}` (0,745) também passam, e as combinações só entram quando melhoram essas confianças em pelo menos 5 pontos. Os lifts (1,20 a 1,41) são menores que os de `Sobreviveu=Sim` (1,84 a 2,53) porque a morte já é a classe majoritária (61,8%): o lift máximo possível para `Sobreviveu=Não` é 1/0,618 = 1,62. Nove das 17 regras de morte usam itens de ausência (`NÃO Classe=1ª`, `NÃO Tarifa=Alta`, `NÃO Família=Pequena`), o que mostra a utilidade da codificação: o que define o grupo de risco é **não** ter os privilégios associados à sobrevivência, qualquer que seja a alternativa.

4.c) Interpretação de regras

	nº	Antecedente	Consequente	Suporte	Confiança	Lift	% cons. na base	Ausência ?
R1	22	{Classe=1ª, Sexo=Feminino}	{Sobreviveu=Sim}	0,106	0,965	2,527	38,2%	não
R2	27	{NÃO Classe=3ª, Sexo=Feminino}	{Sobreviveu=Sim}	0,178	0,932	2,440	38,2%	sim
R3	125	{NÃO Classe=1ª, NÃO Família=Pequena}	{Sobreviveu=Não}	0,410	0,766	1,240	61,8%	sim
R4	109	{Idade=41+, NÃO Classe=1ª}	{Sobreviveu=Não}	0,059	0,786	1,271	61,8%	sim
R5	98	{Família=Grande}	{Sobreviveu=Não}	0,051	0,817	1,322	61,8%	não
R6	71	{Classe=1ª, Sobreviveu=Não}	{Sexo=Masculino}	0,090	0,959	1,490	64,4%	não
R7	24	{Família=Grande}	{Tarifa=Alta}	0,051	0,817	2,511	32,5%	não

Tabela 6 — Regras interpretadas (R2, R3 e R4 com itens de ausência). % cons. na base = taxa geral do consequente; lift = confiança / essa taxa.

R1 — `{Classe=1ª, Sexo=Feminino} → {Sobreviveu=Sim}` (suporte 0,106, confiança 0,965, lift 2,53). Das 144 mulheres da 1ª classe, 139 sobreviveram. É a regra de sobrevivência mais forte e junta os dois fatores mais conhecidos do naufrágio: prioridade às mulheres nos botes e acesso mais fácil ao convés dos botes para a 1ª classe. A melhoria de 0,238 mostra que a combinação vai bem além de cada fator sozinho: só ser mulher dá 0,727 de confiança, e só ser da 1ª classe, 0,619.

R2 — `{NÃO Classe=3ª, Sexo=Feminino} → {Sobreviveu=Sim}` (0,178 / 0,932 / 2,44) — *regra com ausência.* Generaliza a R1: basta a mulher **não** estar na 3ª classe (estar na 1ª **ou** na 2ª) para sobreviver em 93% dos casos. O item de ausência cobre em um único item o grupo "1ª ou 2ª classe", que, só com itens de presença, exigiria duas regras separadas (R1 e `{Classe=2ª, Sexo=Feminino}`, 0,887). A regra tem o maior suporte entre as de sobrevivência com sexo e classe (233 sobreviventes entre 250 mulheres) e deixa claro que a fronteira para as mulheres era a 3ª classe, onde só 49% sobreviveram.

R3 — `{NÃO Classe=1ª, NÃO Família=Pequena} → {Sobreviveu=Não}` (0,410 / 0,766 / 1,24) — *regra com ausência nos dois itens*, no mesmo formato do exemplo do enunciado. Cobre 41% da base: passageiros da 2ª ou 3ª classe que viajavam sozinhos **ou** com família grande. Ela descreve o grupo de risco pelo que lhe falta: não ter o privilégio da 1ª classe e não estar no tamanho de família que mais sobreviveu (famílias pequenas, 56%). Os dois extremos de família (sozinho, 30%; família grande, 18%) se comportam de forma parecida e são agrupados pelo item de ausência.

R4 — `{Idade=41+, NÃO Classe=1ª} → {Sobreviveu=Não}` (0,059 / 0,786 / 1,27) — *regra com ausência.* Entre os passageiros com mais de 40 anos fora da 1ª classe, 78,6% morreram. Com a regra `{Idade=41+, Sobreviveu=Sim} → {Classe=1ª}` (confiança 0,767), ela mostra que **a idade só pesou junto com a classe**: na 1ª classe, os passageiros com mais de 40 anos sobreviveram 53% das vezes, mas na 2ª e na 3ª foram 30% e 12,5%. Ou seja, 77% dos sobreviventes mais velhos eram da 1ª classe.

R5 — `{Família=Grande} → {Sobreviveu=Não}` (0,051 / 0,817 / 1,32). Famílias com 4 ou mais parentes a bordo morreram em 82% dos casos, a pior taxa entre os grupos de família. A regra `{Família=Grande} → {Classe=3ª}` (0,841) ajuda a explicar: essas famílias estavam quase todas na 3ª classe, longe do convés dos botes. Uma explicação provável para a diferença em relação às famílias pequenas é que uma família grande tinha mais dificuldade para se reunir e chegar junta ao convés. A melhoria de 0,199 indica que o efeito vai além da taxa geral de morte.

R6 — `{Classe=1ª, Sobreviveu=Não} → {Sexo=Masculino}` (0,090 / 0,959 / 1,49). Lida ao contrário: dos 123 mortos da 1ª classe, 118 (96%) eram homens. Mesmo no grupo mais privilegiado, a regra de prioridade às mulheres se manteve, e a classe não protegeu os homens (só 34% dos homens da 1ª classe sobreviveram, contra 97% das mulheres). É um bom exemplo de regra em que a sobrevivência aparece no antecedente e o perfil no consequente.

R7 — `{Família=Grande} → {Tarifa=Alta}` (0,051 / 0,817 / 2,51). Parece contradizer a R5 (famílias grandes eram pobres), mas revela uma característica da base: `fare` é o preço do **bilhete**, compartilhado pela família inteira, e não por pessoa. Uma família grande da 3ª classe pagava um bilhete de cerca de £33 (mediana; tarifa "alta" na discretização), mas só cerca de £5,70 por pessoa. A regra serve de alerta: a discretização por tercis tratou como "alta" uma tarifa que, por pessoa, é baixa. Uma melhoria futura seria dividir `fare` pelo número de pessoas no bilhete antes de discretizar.

Conclusão

O Apriori, aplicado ao Titanic com itens de presença e ausência, recupera os padrões já vistos nas Listas 2 e 3 com as árvores de decisão: **sexo** é o fator principal (todas as regras de sobrevivência, menos três, têm `Sexo=Feminino`), seguido de **classe/tarifa** e do **tamanho da família**. A diferença é a forma: em vez de um único caminho de decisão, as regras descrevem o perfil de cada grupo, nos dois sentidos (perfil → sobrevivência e sobrevivência → perfil, como em R6), e mostram relações entre os outros atributos (classe × tarifa × porto de embarque).

Os **itens de ausência** se mostraram úteis para resumir grupos do tipo "qualquer valor menos este" em uma única regra (R2, R3, R4) — 67 das 140 regras finais os usam. O custo é que eles aumentam muito o número de regras redundantes, por isso foram necessários o filtro de atributo repetido e o de melhoria mínima. Sem esses filtros, a mesma configuração (suporte 0,05 / confiança 0,7) geraria 6.491 regras em vez de 140.

A escolha de suporte 0,05 e confiança 0,7, junto com lift ≥ 1,2 e melhoria ≥ 0,05, deixou um conjunto pequeno o bastante para ser lido inteiro, sem regras triviais (lift ~1) nem redundantes, e com regras para os dois desfechos de sobrevivência.

Anexo — Todas as regras finais (suporte ≥ 0,05, confiança ≥ 0,7, lift ≥ 1,2, melhoria ≥ 0,05)

nº	Antecedente	Consequente	Suporte	Confiança	Lift	Melhoria
1	{Embarque=Cherbourg, Tarifa=Alta}	{Classe=1ª}	0,106	0,927	3,755	0,220
2	{Idade=41+, Tarifa=Alta}	{Classe=1ª}	0,092	0,903	3,659	0,196
3	{NÃO Embarque=Southampton, Tarifa=Alta}	{Classe=1ª}	0,108	0,893	3,619	0,187
4	{Família=Sozinho, Tarifa=Alta}	{Classe=1ª}	0,106	0,891	3,611	0,184
5	{Sobreviveu=Sim, Tarifa=Alta}	{Classe=1ª}	0,148	0,812	3,290	0,105
6	{NÃO Família=Grande, Tarifa=Alta}	{Classe=1ª}	0,222	0,808	3,274	0,101
7	{NÃO Idade=0-12, Tarifa=Alta}	{Classe=1ª}	0,226	0,779	3,157	0,072
8	{Idade=41+, Sobreviveu=Sim}	{Classe=1ª}	0,053	0,767	3,107	0,196
9	{Idade=23-40, Tarifa=Alta}	{Classe=1ª}	0,108	0,766	3,106	0,060
10	{Classe=1ª, NÃO Família=Sozinho}	{Tarifa=Alta}	0,124	0,994	3,054	0,062
11	{Classe=1ª, Família=Pequena}	{Tarifa=Alta}	0,115	0,993	3,053	0,062
12	{Classe=1ª, NÃO Embarque=Southampton}	{Tarifa=Alta}	0,108	0,986	3,030	0,054
13	{Classe=1ª, Embarque=Cherbourg}	{Tarifa=Alta}	0,106	0,986	3,029	0,054
14	{Idade=41+, NÃO Tarifa=Média}	{Classe=1ª}	0,093	0,726	2,943	0,156
15	{Classe=1ª}	{Tarifa=Alta}	0,230	0,932	2,863	0,606
16	{Tarifa=Alta}	{Classe=1ª}	0,230	0,707	2,863	0,460
17	{Classe=2ª, NÃO Família=Pequena}	{Tarifa=Média}	0,112	0,912	2,791	0,151
18	{Classe=2ª, Família=Sozinho}	{Tarifa=Média}	0,110	0,911	2,787	0,150
19	{Embarque=Cherbourg, NÃO Classe=3ª}	{Tarifa=Alta}	0,115	0,888	2,727	0,286
20	{NÃO Classe=3ª, NÃO Embarque=Southampton}	{Tarifa=Alta}	0,117	0,855	2,626	0,253
21	{Embarque=Queenstown, Família=Sozinho}	{Tarifa=Baixa}	0,067	0,898	2,583	0,158
22	{Classe=1ª, Sexo=Feminino}	{Sobreviveu=Sim}	0,106	0,965	2,527	0,238
23	{Classe=3ª, Família=Pequena}	{Tarifa=Média}	0,105	0,821	2,512	0,355
24	{Família=Grande}	{Tarifa=Alta}	0,051	0,817	2,511	0,492
25	{Classe=3ª, Família=Sozinho}	{Tarifa=Baixa}	0,312	0,867	2,493	0,245
26	{Classe=2ª, Idade=23-40}	{Tarifa=Média}	0,097	0,814	2,490	0,052
27	{NÃO Classe=3ª, Sexo=Feminino}	{Sobreviveu=Sim}	0,178	0,932	2,440	0,205
28	{Embarque=Queenstown, NÃO Família=Pequena}	{Tarifa=Baixa}	0,067	0,846	2,434	0,106
29	{Idade=41+, NÃO Família=Sozinho}	{Tarifa=Alta}	0,063	0,790	2,429	0,203
30	{Família=Pequena, Idade=41+}	{Tarifa=Alta}	0,057	0,781	2,401	0,194
31	{Embarque=Cherbourg, Sexo=Feminino}	{Sobreviveu=Sim}	0,078	0,903	2,363	0,175
32	{Idade=41+, Sobreviveu=Sim}	{Tarifa=Alta}	0,053	0,767	2,356	0,179
33	{Idade=13-22, Sobreviveu=Sim}	{Sexo=Feminino}	0,077	0,835	2,345	0,157
34	{NÃO Classe=3ª, NÃO Família=Sozinho}	{Tarifa=Alta}	0,163	0,759	2,332	0,157
35	{Classe=2ª}	{Tarifa=Média}	0,161	0,762	2,330	0,435
36	{Classe=2ª, Sexo=Feminino}	{Sobreviveu=Sim}	0,072	0,887	2,322	0,159
37	{Família=Pequena, NÃO Classe=3ª}	{Tarifa=Alta}	0,155	0,755	2,319	0,153
38	{Classe=3ª, Embarque=Queenstown}	{Tarifa=Baixa}	0,070	0,805	2,317	0,065
39	{Sexo=Feminino, Tarifa=Alta}	{Sobreviveu=Sim}	0,128	0,862	2,256	0,134
40	{Idade=41+, NÃO Classe=3ª}	{Tarifa=Alta}	0,099	0,722	2,219	0,121
41	{Classe=2ª, Sobreviveu=Sim}	{Sexo=Feminino}	0,072	0,790	2,219	0,112
42	{NÃO Classe=3ª, Sobreviveu=Sim}	{Tarifa=Alta}	0,176	0,721	2,215	0,119
43	{Classe=3ª, NÃO Família=Pequena}	{Tarifa=Baixa}	0,314	0,760	2,186	0,138
44	{Família=Pequena, NÃO Classe=1ª}	{Tarifa=Média}	0,155	0,712	2,178	0,245
45	{Idade=41+, NÃO Classe=2ª}	{Tarifa=Alta}	0,095	0,702	2,158	0,115
46	{Idade=13-22, NÃO Embarque=Southampton}	{Sexo=Feminino}	0,054	0,763	2,145	0,253
47	{Embarque=Queenstown}	{Tarifa=Baixa}	0,070	0,740	2,128	0,392
48	{NÃO Família=Sozinho, Sobreviveu=Sim}	{Sexo=Feminino}	0,150	0,755	2,120	0,077

nº	Antecedente	Consequente	Suporte	Confiança	Lift	Melhoria
49	{Família=Pequena, Sobreviveu=Sim}	{Sexo=Feminino}	0,141	0,752	2,112	0,074
50	{NÃO Embarque=Southampton, Sexo=Feminino}	{Sobreviveu=Sim}	0,106	0,803	2,103	0,076
51	{Família=Pequena, Sexo=Feminino}	{Sobreviveu=Sim}	0,141	0,801	2,097	0,073
52	{Sobreviveu=Sim, Tarifa=Média}	{Sexo=Feminino}	0,090	0,733	2,059	0,055
53	{NÃO Classe=3ª, Sobreviveu=Sim}	{Sexo=Feminino}	0,178	0,730	2,052	0,052
54	{Classe=3ª, Sexo=Masculino}	{Tarifa=Baixa}	0,264	0,702	2,019	0,080
55	{Família=Sozinho, Idade=13-22}	{Tarifa=Baixa}	0,100	0,701	2,015	0,165
56	{Sexo=Feminino}	{Sobreviveu=Sim}	0,259	0,727	1,905	0,345
57	{Classe=1ª, NÃO Família=Sozinho}	{Sobreviveu=Sim}	0,090	0,724	1,895	0,105
58	{Classe=1ª, Família=Pequena}	{Sobreviveu=Sim}	0,084	0,724	1,895	0,104
59	{Família=Pequena, Tarifa=Alta}	{Sobreviveu=Sim}	0,109	0,704	1,844	0,142
60	{Embarque=Queenstown, NÃO Tarifa=Média}	{Classe=3ª}	0,074	0,970	1,791	0,051
61	{Tarifa=Baixa}	{Classe=3ª}	0,337	0,969	1,789	0,428
62	{Embarque=Queenstown}	{Classe=3ª}	0,086	0,919	1,696	0,377
63	{Família=Grande, NÃO Embarque=Cherbourg}	{Classe=3ª}	0,053	0,896	1,654	0,055
64	{NÃO Embarque=Southampton, NÃO Tarifa=Alta}	{Classe=3ª}	0,159	0,889	1,641	0,160
65	{Sexo=Feminino, Sobreviveu=Não}	{Classe=3ª}	0,084	0,866	1,599	0,213
66	{Idade=13-22, NÃO Tarifa=Alta}	{Classe=3ª}	0,149	0,855	1,579	0,126
67	{Embarque=Cherbourg, NÃO Tarifa=Alta}	{Classe=3ª}	0,077	0,842	1,554	0,112
68	{Família=Grande}	{Classe=3ª}	0,053	0,841	1,554	0,300
69	{Tarifa=Baixa}	{Família=Sozinho}	0,323	0,930	1,540	0,326
70	{Idade=13-22, Sobreviveu=Não}	{Classe=3ª}	0,106	0,822	1,519	0,102
71	{Classe=1ª, Sobreviveu=Não}	{Sexo=Masculino}	0,090	0,959	1,490	0,116
72	{Idade=13-22, NÃO Família=Pequena}	{Classe=3ª}	0,127	0,798	1,473	0,077
73	{Família=Sozinho, Idade=13-22}	{Classe=3ª}	0,114	0,797	1,471	0,076
74	{NÃO Classe=3ª, Sobreviveu=Não}	{Sexo=Masculino}	0,202	0,940	1,459	0,096
75	{Embarque=Queenstown, NÃO Tarifa=Média}	{Família=Sozinho}	0,067	0,880	1,458	0,083
76	{Idade=13-22, NÃO Embarque=Southampton}	{Classe=3ª}	0,056	0,785	1,449	0,064
77	{Classe=2ª, Sobreviveu=Não}	{Sexo=Masculino}	0,112	0,924	1,435	0,081
78	{Embarque=Queenstown, NÃO Tarifa=Alta}	{Família=Sozinho}	0,075	0,860	1,424	0,063
79	{Embarque=Cherbourg, Sobreviveu=Não}	{Sexo=Masculino}	0,083	0,908	1,410	0,065
80	{Sexo=Masculino, Tarifa=Baixa}	{Sobreviveu=Não}	0,239	0,869	1,407	0,060
81	{Idade=41+, Sobreviveu=Não}	{Sexo=Masculino}	0,095	0,906	1,407	0,063
82	{Família=Sozinho, Sobreviveu=Não}	{Sexo=Masculino}	0,381	0,906	1,406	0,063
83	{Idade=13-22, Sexo=Masculino}	{Sobreviveu=Não}	0,093	0,859	1,390	0,050
84	{NÃO Idade=13-22, Tarifa=Baixa}	{Sexo=Masculino}	0,212	0,894	1,387	0,102
85	{Idade=23-40, Tarifa=Baixa}	{Sexo=Masculino}	0,186	0,890	1,382	0,099
86	{Idade=23-40, Tarifa=Baixa}	{Sobreviveu=Não}	0,177	0,850	1,375	0,070
87	{Classe=3ª, NÃO Tarifa=Média}	{Família=Sozinho}	0,319	0,826	1,369	0,160
88	{NÃO Idade=13-22, Tarifa=Baixa}	{Sobreviveu=Não}	0,200	0,845	1,368	0,065
89	{NÃO Família=Pequena, NÃO Tarifa=Média}	{Classe=3ª}	0,364	0,735	1,356	0,114
90	{NÃO Tarifa=Média, Sobreviveu=Não}	{Classe=3ª}	0,304	0,734	1,356	0,082
91	{NÃO Tarifa=Alta}	{Classe=3ª}	0,492	0,729	1,347	0,188
92	{Embarque=Southampton, Tarifa=Baixa}	{Sexo=Masculino}	0,202	0,866	1,345	0,075
93	{NÃO Embarque=Queenstown, Tarifa=Baixa}	{Sexo=Masculino}	0,241	0,865	1,344	0,074
94	{NÃO Idade=41+, Sobreviveu=Não}	{Classe=3ª}	0,371	0,724	1,337	0,072
95	{NÃO Tarifa=Alta, Sexo=Masculino}	{Família=Sozinho}	0,377	0,806	1,335	0,088
96	{Família=Sozinho, NÃO Tarifa=Média}	{Classe=3ª}	0,319	0,722	1,333	0,124
97	{Idade=13-22}	{Classe=3ª}	0,160	0,721	1,331	0,179
98	{Família=Grande}	{Sobreviveu=Não}	0,051	0,817	1,322	0,199
99	{Idade=0-12}	{Classe=3ª}	0,056	0,716	1,321	0,174
100	{Embarque=Queenstown}	{Família=Sozinho}	0,075	0,797	1,320	0,193

nº	Antecedente	Consequente	Suporte	Confiança	Lift	Melhoria
101	{Sobreviveu=Não}	{Sexo=Masculino}	0,521	0,843	1,309	0,199
102	{Sexo=Masculino}	{Sobreviveu=Não}	0,521	0,809	1,309	0,191
103	{Idade=23-40, Sexo=Masculino}	{Família=Sozinho}	0,296	0,785	1,301	0,078
104	{Classe=3ª, Idade=23-40}	{Sobreviveu=Não}	0,231	0,799	1,294	0,055
105	{Idade=41+, NÃO Classe=1ª}	{Embarque=Southampton}	0,067	0,898	1,283	0,150
106	{NÃO Tarifa=Alta, Sobreviveu=Não}	{Família=Sozinho}	0,367	0,772	1,279	0,054
107	{Idade=41+, NÃO Tarifa=Alta}	{Embarque=Southampton}	0,064	0,894	1,277	0,159
108	{NÃO Classe=3ª, NÃO Tarifa=Alta}	{Embarque=Southampton}	0,163	0,891	1,274	0,156
109	{Idade=41+, NÃO Classe=1ª}	{Sobreviveu=Não}	0,059	0,786	1,271	0,090
110	{NÃO Classe=3ª, Tarifa=Média}	{Embarque=Southampton}	0,152	0,884	1,264	0,083
111	{Família=Sozinho, Idade=23-40}	{Sexo=Masculino}	0,296	0,813	1,262	0,059
112	{Tarifa=Baixa}	{Sobreviveu=Não}	0,271	0,780	1,262	0,162
113	{Família=Sozinho, Idade=41+}	{Sexo=Masculino}	0,076	0,813	1,262	0,059
114	{Idade=23-40, NÃO Tarifa=Média}	{Família=Sozinho}	0,266	0,761	1,262	0,071
115	{Família=Sozinho, NÃO Idade=13-22}	{Sexo=Masculino}	0,374	0,811	1,259	0,057
116	{Embarque=Southampton, Família=Sozinho}	{Sexo=Masculino}	0,345	0,810	1,257	0,055
117	{Idade=41+, NÃO Tarifa=Alta}	{Sobreviveu=Não}	0,056	0,777	1,257	0,072
118	{Classe=3ª, Idade=23-40}	{Sexo=Masculino}	0,234	0,807	1,254	0,092
119	{NÃO Classe=1ª, NÃO Tarifa=Média}	{Família=Sozinho}	0,330	0,755	1,251	0,098
120	{Classe=3ª, Idade=23-40}	{Família=Sozinho}	0,218	0,755	1,250	0,064
121	{Classe=2ª}	{Embarque=Southampton}	0,185	0,874	1,248	0,174
122	{Idade=23-40, NÃO Tarifa=Alta}	{Sobreviveu=Não}	0,297	0,770	1,246	0,066
123	{Idade=23-40, Sobreviveu=Não}	{Família=Sozinho}	0,262	0,751	1,244	0,060
124	{Idade=23-40, NÃO Família=Pequena}	{Sexo=Masculino}	0,303	0,798	1,240	0,068
125	{NÃO Classe=1ª, NÃO Família=Pequena}	{Sobreviveu=Não}	0,410	0,766	1,240	0,057
126	{NÃO Família=Pequena, Tarifa=Média}	{Embarque=Southampton}	0,148	0,866	1,238	0,065
127	{Família=Grande}	{Embarque=Southampton}	0,054	0,866	1,237	0,166
128	{NÃO Classe=1ª, Tarifa=Alta}	{Embarque=Southampton}	0,083	0,864	1,235	0,117
129	{NÃO Tarifa=Média, Sobreviveu=Não}	{Família=Sozinho}	0,307	0,742	1,229	0,061
130	{Tarifa=Baixa}	{Sexo=Masculino}	0,275	0,791	1,229	0,147
131	{Família=Sozinho, Tarifa=Média}	{Embarque=Southampton}	0,138	0,858	1,226	0,056
132	{Família=Sozinho, NÃO Tarifa=Alta}	{Sobreviveu=Não}	0,367	0,757	1,225	0,053
133	{Classe=3ª, NÃO Idade=0-12}	{Família=Sozinho}	0,358	0,737	1,222	0,072
134	{NÃO Família=Pequena, NÃO Idade=13-22}	{Sexo=Masculino}	0,398	0,785	1,218	0,054
135	{Idade=23-40, NÃO Classe=1ª}	{Sobreviveu=Não}	0,307	0,751	1,216	0,056
136	{Família=Sozinho, NÃO Classe=1ª}	{Sobreviveu=Não}	0,361	0,751	1,215	0,053
137	{NÃO Classe=1ª, NÃO Tarifa=Média}	{Sobreviveu=Não}	0,327	0,748	1,211	0,053
138	{Idade=13-22, Sexo=Masculino}	{Embarque=Southampton}	0,092	0,845	1,208	0,106
139	{Idade=23-40, NÃO Tarifa=Alta}	{Sexo=Masculino}	0,299	0,776	1,205	0,061
140	{Classe=3ª}	{Sobreviveu=Não}	0,403	0,745	1,205	0,127

Tabela 7 — As 140 regras finais, ordenadas por lift.